

Q-learning динамика на графе: постановка, сходимость и сравнение с динамикой Константинова

Содержание

1	Введение	3
2	Формальная постановка модели	3
2.1	Граф и агенты	3
2.2	Модели наград	3
2.3	Режимы проведения игры	3
2.4	Метрика кооперации	4
2.5	Базовая динамика (по Константинову)	4
3	Q-learning и SARSA: правила обучения	4
3.1	Что хранит агент и как принимает решения	4
3.2	Политики выбора действий	4
3.3	Правила обновления	4
4	Стационарный анализ	5
4.1	Уравнение Беллмана	5
4.2	Ключевая лемма: разность Q-значений	5
4.3	Разность наград для всех моделей	6
4.4	Формулы стационарной кооперации	6
4.5	Примеры для конкретных графов	6
5	Учёт корреляций: откуда зависимость от b	7
5.1	Почему приближение нарушается	7
5.2	Поправка первого порядка	7
5.3	Отличие SARSA от Q-learning при ε -жадной политике	7
6	Сходимость	7
6.1	Почему стандартная теорема не работает	7
6.2	Полное состояние системы	8
6.3	Неподвижная точка: определение и существование	8
6.4	Стохастическая природа обучения	8
6.5	ODE-метод: связь со стохастической аппроксимацией	9
6.6	Устойчивость: оценка якобиана	9
6.7	Основная теорема о сходимости	10

6.8	Обсуждение условия $\Lambda < 1$	10
6.9	SARSA: аналогичная теорема	11
7	Monte Carlo режим	11
7.1	Почему базовая формула не переносится	11
8	Сводка результатов	12
9	Численные эксперименты	12
9.1	Настройки	12
9.2	Наблюдения	12
10	Заключение	12

1. Введение

Рассматривается динамика обучения с подкреплением в сетевых социальных дилеммах. Цель работы — формализовать модель, описать используемые правила обучения (Q-learning и SARSA), вывести формулы стационарной кооперации и строго исследовать вопрос сходимости.

Отдельное внимание уделяется «гранулярному» монте-карло обновлению, когда за один раунд активна только локальная гранула узлов, а также сравнению с имитационной динамикой Константинова и гранулярным Q-learning (Interactive Identity / Interactive Diversity) из работы Lee–Weng (Chaos, Solitons and Fractals, 2025).

2. Формальная постановка модели

2.1. Граф и агенты

Задан неориентированный граф $G = (V, E)$, $|V| = n$:

- $W = (w_{ij})$ — матрица смежности, $w_{ij} \in \{0, 1\}$, $w_{ii} = 0$;
- $N_i = \{j : w_{ij} = 1\}$ — соседи агента i ;
- $k_i = |N_i|$ — степень узла.

Каждый агент i в момент t выбирает действие $x_i^t \in \{0, 1\}$, где $0 = \text{Defect}$, $1 = \text{Cooperate}$.

2.2. Модели наград

Мгновенная награда агента i определяется одной из четырёх моделей. Первая буква — тип производства награды (р — пропорциональная степени, f — фиксированная), вторая — тип издержек:

$$\text{pp: } g_i = b \sum_{j \in N_i} w_{ij} x_j - c \cdot x_i \cdot k_i, \quad (1)$$

$$\text{pf: } g_i = b \sum_{j \in N_i} w_{ij} x_j - c \cdot x_i, \quad (2)$$

$$\text{ff: } g_i = b \sum_{j \in N_i} \frac{w_{ij} x_j}{k_j} - c \cdot x_i, \quad (3)$$

$$\text{fp: } g_i = b \sum_{j \in N_i} \frac{w_{ij} x_j}{k_j} - c \cdot x_i \cdot k_i, \quad (4)$$

где $b > c > 0$.

Все четыре модели имеют одну и ту же структуру:

$$g_i = B_i(\mathbf{x}_{-i}) - C_i \cdot x_i, \quad (5)$$

где B_i зависит только от соседей, а C_i — эффективная цена кооперации: $C_i^{\text{pp}} = C_i^{\text{fp}} = c k_i$, $C_i^{\text{pf}} = C_i^{\text{ff}} = c$.

2.3. Режимы проведения игры

Режим 1 (одновременная игра): все рёбра играют одновременно.

Режим 2 (Monte Carlo): выбираются k_{anch} опорных агентов равномерно из V ; игра проводится на индуцированном подграфе. При $k_{\text{anch}} = n$ вырождается в режим 1.

2.4. Метрика кооперации

Мгновенная доля кооператоров: $\rho(t) = n^{-1} \sum_i x_i^t$.

Стационарная кооперация: $\hat{\rho}$ — среднее $\rho(t)$ по последним шагам.

2.5. Базовая динамика (по Константинову)

Для сравнения: детерминированное имитационное правило, в котором агент i копирует стратегию соседа с максимальной наградой.

3. Q-learning и SARSA: правила обучения

3.1. Что хранит агент и как принимает решения

Каждый агент i хранит Q-таблицу $Q_i(s, a)$ — таблицу размера $(k_i + 1) \times 2$, где строки соответствуют наблюдениям $s \in \{0, 1, \dots, k_i\}$, а столбцы — действиям $a \in \{0, 1\}$.

Агент принимает решение в два шага:

1. Наблюдает $s_i^t = \sum_{j \in N_i} x_j^t$ — число кооперирующих соседей.
2. Выбирает действие x_i^{t+1} по своей Q-таблице и политике.

Подчеркнём: **действие определяется Q-таблицей, а не наблюдением напрямую.** Наблюдение s_i служит лишь индексом строки в Q-таблице. Два агента с одинаковым s , но разными Q-таблицами примут разные решения.

Замечание 3.1 (О природе «состояния»). В терминологии MDP «состояние» — это то, что агент наблюдает из среды. Величина $s_i = \sum_j x_j$ — наблюдаемая характеристика окружения, а Q-таблица — внутренняя память агента, сконденсировавшая весь его прошлый опыт. В стационарном режиме (когда Q-таблица перестала меняться) s_i полностью определяет поведение. В процессе обучения полное описание системы требует знания всех Q-таблиц всех агентов (см. раздел 6).

3.2. Политики выбора действий

ϵ -жадная:

$$P_i(a | s) = \begin{cases} 1 - \epsilon/2, & \text{если } a = \arg \max_{a'} Q_i(s, a'), \\ \epsilon/2, & \text{иначе.} \end{cases} \quad (6)$$

Больцмановская:

$$P_i(a | s) = \frac{e^{Q_i(s,a)/T}}{e^{Q_i(s,0)/T} + e^{Q_i(s,1)/T}}, \quad (7)$$

где $T > 0$ — температура: $T \rightarrow 0$ даёт жадную, $T \rightarrow \infty$ — равномерную политику.

3.3. Правила обновления

Q-learning (off-policy):

$$Q_i(s_t, a_t) \leftarrow Q_i(s_t, a_t) + \alpha [r_{i,t} + \gamma \max_{a'} Q_i(s_{t+1}, a') - Q_i(s_t, a_t)]. \quad (8)$$

SARSA (on-policy):

$$Q_i(s_t, a_t) \leftarrow Q_i(s_t, a_t) + \alpha [r_{i,t} + \gamma Q_i(s_{t+1}, a_{t+1}) - Q_i(s_t, a_t)], \quad (9)$$

где $r_{i,t} = g_i^t$ — награда, $\alpha \in (0, 1]$ — шаг обучения, $\gamma \in [0, 1)$ — дисконт, a_{t+1} — действие, реально выбранное на шаге $t + 1$.

Отличие: Q-learning подставляет $\max$ («что бы я сделал в лучшем случае»), SARSA — реальное следующее действие («что я реально сделаю, включая случайные ошибки»). SARSA поэтому более «осторожен».

4. Стационарный анализ

Здесь мы предполагаем, что Q-таблицы уже пришли в равновесие, и выводим формулы для стационарной кооперации. Вопрос о том, когда и почему Q-таблицы сходятся, разбирается в разделе 6.

4.1. Уравнение Беллмана

Теорема 4.1. Пусть все агенты, кроме i , играют фиксированные стратегии. Тогда оптимальная Q-функция агента i удовлетворяет:

$$Q_i^*(s, a) = \mathbb{E}[R_i(s, a)] + \gamma \sum_{s'} P(s'|s, a) \max_{a'} Q_i^*(s', a'). \quad (10)$$

Доказательство. При фиксированных стратегиях остальных агентов задача агента i — конечный MDP с $|S| = k_i + 1$ состояниями и $|A| = 2$ действиями. При $\gamma < 1$ оператор Беллмана — сжимающий с коэффициентом γ , его неподвижная точка Q_i^* существует и единственна (Puterman, 1994, теорема 6.2.3). $\square$

Для SARSA аналогичное уравнение содержит ожидание по политике π вместо $\max$:

$$Q_i^\pi(s, a) = \mathbb{E}[R_i(s, a)] + \gamma \sum_{s'} P(s'|s, a) \sum_{a'} \pi(a'|s') Q_i^\pi(s', a'). \quad (11)$$

4.2. Ключевая лемма: разность Q-значений

Лемма 4.2 (Независимость переходов). Если $P(s'|s, a = 0) = P(s'|s, a = 1)$ для всех s, s' , то

$$Q_i^*(s, 1) - Q_i^*(s, 0) = \mathbb{E}[R_i(s, 1)] - \mathbb{E}[R_i(s, 0)]. \quad (12)$$

То же верно для SARSA: $Q_i^\pi(s, 1) - Q_i^\pi(s, 0) = \mathbb{E}[R_i(s, 1)] - \mathbb{E}[R_i(s, 0)]$.

В обоих случаях разность не зависит от γ .

Доказательство. Обозначим $\Delta Q(s) = Q(s, 1) - Q(s, 0)$.

Q-learning. Вычтем (10) при $a = 0$ из $a = 1$:

$$\Delta Q_i^*(s) = \Delta R_i(s) + \gamma \sum_{s'} (P(s'|s, 1) - P(s'|s, 0)) \max_{a'} Q_i^*(s', a').$$

При $P(s'|s, 1) = P(s'|s, 0)$ второе слагаемое = 0.

SARSA. Аналогично, из (11):

$$\Delta Q_i^\pi(s) = \Delta R_i(s) + \gamma \sum_{s'} (P(s'|s, 1) - P(s'|s, 0)) \sum_{a'} \pi(a'|s') Q_i^\pi(s', a').$$

Опять обращается в ноль. $\square$

4.3. Разность наград для всех моделей

Теорема 4.3. Для моделей (1)–(4):

$$\Delta R_i \equiv g_i(x_i=1, \mathbf{x}_{-i}) - g_i(x_i=0, \mathbf{x}_{-i}) = -C_i. \quad (13)$$

Конкретно: $\Delta R_i = -ck_i$ для pp и fp ; $\Delta R_i = -c$ для pf и ff .

Разность не зависит от b , от $\mathbf{x}_{-i}$ и от s .

Доказательство. Из структуры (5): $\Delta R_i = (B_i - C_i \cdot 1) - (B_i - C_i \cdot 0) = -C_i$. Слагаемое B_i сокращается. $\square$

Следствие 4.4. Модели попарно эквивалентны по стационарной кооперации: $pp \sim fp$ (пропорциональные издержки) и $pf \sim ff$ (фиксированные). Это согласуется с наблюдением Константинова: «игры разделяются по типу издержек».

4.4. Формулы стационарной кооперации

Теорема 4.5. В приближении леммы 4.2, при Больцмановской политике, стационарная вероятность кооперации агента i :

$$p_i = \frac{1}{1 + e^{C_i/T}}. \quad (14)$$

Средняя кооперация $\hat{\rho} = n^{-1} \sum_i p_i$. Формулы одинаковы для Q -learning и SARSA.

$$\text{Модели } pp \text{ и } fp: \hat{\rho} = \frac{1}{n} \sum_{i=1}^n \frac{1}{1 + e^{ck_i/T}}.$$

$$\text{Модели } pf \text{ и } ff: \hat{\rho} = \frac{1}{1 + e^{c/T}}.$$

Доказательство. При Больцмановской политике: $P(a=1|s) = \sigma(\Delta Q(s)/T)$, где $\sigma(z) = 1/(1+e^{-z})$. По лемме 4.2: $\Delta Q(s) = -C_i$. Подставляем: $p_i = \sigma(-C_i/T) = 1/(1+e^{C_i/T})$. $\square$

Замечание 4.6 (Независимость от b). Формулы не зависят от b . Наблюдаемая в экспериментах зависимость $\hat{\rho}$ от b возникает из-за нарушения условия леммы 4.2 (раздел 5).

4.5. Примеры для конкретных графов

Теорема 4.7 (Звезда S_n). Центр: степень n . Листья: степень 1. Для pp/fp :

$$\hat{\rho} = \frac{1}{n+1} \left[\frac{n}{1 + e^{c/T}} + \frac{1}{1 + e^{cn/T}} \right].$$

При $n \rightarrow \infty$: $\hat{\rho} \rightarrow 1/(1 + e^{c/T})$ (центр всегда предаёт).

Доказательство. Подставляем $k_{\text{leaf}} = 1$, $k_{\text{center}} = n$ в формулу теоремы 4.5. $\square$

Следствие 4.8 (k -регулярный граф). $\hat{\rho}_{pp} = 1/(1 + e^{ck/T})$. Кооперация убывает с ростом k , что согласуется с Константиновым.

5. Учёт корреляций: откуда зависимость от b

5.1. Почему приближение нарушается

Действие $x_i^t = a$ входит в состояние каждого соседа j : $s_j^t = \sum_{l \in N_j} x_l^t$. Через политику j -го агента это влияет на x_j^{t+1} , а значит на s_i^{t+1} . Переходы $P(s'|s, a)$ зависят от a — условие леммы 4.2 нарушено.

5.2. Поправка первого порядка

Теорема 5.1. На k -регулярном графе, модель pp , Больцмановская политика. Пусть все агенты имеют одинаковую вероятность кооперации p . Тогда:

$$\Delta Q_i^* \approx -ck + \frac{\gamma b p(1-p) b/T}{1-\gamma}. \quad (15)$$

Доказательство. **Шаг 1.** Действие $x_i = 1$ вместо 0 увеличивает s_j на 1 для каждого $j \in N_i$.

Шаг 2. Изменение s_j на 1 сдвигает вероятность кооперации j на $\delta = p(1-p) \cdot (\partial \Delta Q / \partial s) / T$. В нулевом приближении ΔQ не зависит от s , значит $\partial \Delta Q / \partial s \approx b$ (от первого слагаемого $B_j = b \cdot s_j$). Итого $\delta \approx p(1-p) b/T$.

Шаг 3. Каждый из k соседей увеличивает вероятность кооперации на δ , что увеличивает ожидаемое s_i^{t+1} на $k\delta$ и награду на $b \cdot k\delta$.

Шаг 4. Эффект каскадируется: $\Delta Q_{\text{feedback}} = \sum_{\tau=1}^{\infty} \gamma^\tau \cdot bk\delta = \gamma bk\delta / (1-\gamma)$.

Складываем с базовым $-ck$: $\Delta Q_i^* \approx -ck + \gamma bk\delta / (1-\gamma) = -ck + \gamma b^2 k p(1-p) / [T(1-\gamma)]$. $\square$

Из формулы видно: при росте b поправка увеличивается, делая ΔQ менее отрицательным, что повышает кооперацию.

5.3. Отличие SARSA от Q-learning при ε -жадной политике

Утверждение 5.2. SARSA с ε -жадной политикой даёт дополнительный штраф:

$$\delta_{\text{SARSA}} = \frac{\gamma \varepsilon ck}{2(1-\gamma)}, \quad (16)$$

уменьшающий кооперацию по сравнению с Q-learning.

Доказательство. Q-learning оценивает будущее как $\max_{a'} Q(s', a')$ — наилучшее действие. SARSA оценивает $\sum_{a'} \pi(a'|s') Q(s', a')$ — включая вероятность $\varepsilon/2$ случайного предательства. Потеря от одного случайного предательства: $C_i = ck$. Дисконтированная сумма: $\gamma \cdot (\varepsilon/2) \cdot ck / (1-\gamma)$. $\square$

6. Сходимость

6.1. Почему стандартная теорема не работает

Классическая теорема о сходимости Q-learning (Watkins, Dayan, 1992) требует стационарности среды. В нашей модели среда агента i — это политики всех соседей, определяемые их Q-таблицами. Поскольку все Q-таблицы обновляются одновременно, среда каждого агента нестационарна. Стандартная теорема неприменима.

6.2. Полное состояние системы

Определение 6.1. Полное состояние системы в момент t :

$$\Omega^t = (Q_1^t, \dots, Q_n^t, x_1^t, \dots, x_n^t).$$

Здесь $Q_i^t \in \mathbb{R}^{(k_i+1) \times 2}$ — Q-таблица агента i , $x_i^t \in \{0, 1\}$ — его текущее действие.

Динамика за один шаг:

1. Каждый агент наблюдает $s_i^t = \sum_{j \in N_i} x_j^t$.
2. Каждый выбирает $x_i^{t+1} \sim \pi_i(\cdot | s_i^t; Q_i^t)$.
3. Каждый получает $r_i^t = g_i(\mathbf{x}^t)$ и обновляет $Q_i^t \rightarrow Q_i^{t+1}$.

6.3. Неподвижная точка: определение и существование

Определение 6.2. Набор Q-таблиц $\mathbf{Q}^* = (Q_1^*, \dots, Q_n^*)$ — *неподвижная точка*, если для каждого i таблица Q_i^* является решением уравнения Беллмана в среде, порождённой стационарными политиками $\pi_j(\cdot; Q_j^*)$ всех остальных агентов.

Это равновесие Нэша в пространстве Q-таблиц: каждый агент играет лучший ответ на остальных.

Теорема 6.3 (Существование). *Неподвижная точка существует.*

Доказательство. Определим отображение $\Phi: \mathcal{Q} \rightarrow \mathcal{Q}$, где $\mathcal{Q} = \prod_i \mathbb{R}^{(k_i+1) \times 2}$:

$$[\Phi(\mathbf{Q})]_i = \text{решение Беллмана агента } i \text{ в среде с политиками } \pi_j(\cdot; Q_j), j \neq i.$$

Корректность: при фиксированных Q_j среда агента i — конечный стационарный MDP. При $\gamma < 1$ решение Беллмана существует и единственно.

Непрерывность: Больцмановская политика $\pi_j(a|s; Q_j) = e^{Q_j(s,a)/T} / Z$ непрерывно зависит от Q_j (при $T > 0$). Переходы P_i — полиномы от вероятностей. Решение Беллмана непрерывно зависит от P и R (непрерывная зависимость неподвижной точки сжимающего оператора от параметра).

Компактность: Q-значения ограничены $|Q_i(s, a)| \leq R_{\max} / (1 - \gamma)$, где $R_{\max} = \max |g_i|$. Это компактное выпуклое множество, и Φ переводит его в себя.

По теореме Брауэра: непрерывное отображение компактного выпуклого множества в себя имеет неподвижную точку. $\square$

Замечание 6.4. Единственность не гарантирована: может быть несколько равновесий (например, «все кооперируют» и «все предают»).

6.4. Стохастическая природа обучения

Важное наблюдение: даже если Q-таблицы равны Q^* , после одного шага они сдвинутся. Причина в том, что Q-learning обновляет значения по *одной реализации* (s, a, r, s') , а не по ожиданию.

Пример 6.5. Пусть все Q-таблицы равны Q^* . По Больцмановской политике с вероятностью $(1 - p_0)^n > 0$ все агенты выберут Defect. Тогда все получают $r = 0$ и увидят $s' = 0$. Обновление Q-learning:

$$Q_i^{\text{new}}(s_t, 0) = Q^*(s_t, 0) + \alpha [0 + \gamma \max_{a'} Q^*(0, a') - Q^*(s_t, 0)].$$

Уравнение Беллмана для $Q^*(s_t, 0)$ содержит *ожидание* по s' , а не конкретное $s' = 0$. Поэтому в общем случае $Q_i^{\text{new}} \neq Q^*$ — таблица сдвинется.

Таким образом, вопрос сходимости — это не «останется ли Q-таблица на месте», а «будут ли отклонения от Q^* в среднем убывать».

6.5. ODE-метод: связь со стохастической аппроксимацией

Запишем обновление Q-таблицы в виде:

$$Q_i^{t+1}(s, a) = Q_i^t(s, a) + \alpha_t \cdot \mathbb{I}_{(s_i^t, a_i^t) = (s, a)} \cdot \underbrace{[\bar{h}_i(s, a; \mathbf{Q}^t) - Q_i^t(s, a)]}_{\text{дрейф}} + \underbrace{\xi_i^t(s, a)}_{\text{шум}}, \quad (17)$$

где $\bar{h}_i(s, a; \mathbf{Q})$ — ожидаемая «цель» обновления при фиксированных Q-таблицах $\mathbf{Q}$:

$$\bar{h}_i(s, a; \mathbf{Q}) = \mathbb{E}_{\pi(\mathbf{Q})} [r_i + \gamma \max_{a'} Q_i(s', a') \mid s_i = s, a_i = a],$$

а ξ_i^t — шум (разность между реализацией и ожиданием).

При малом α траектория $\mathbf{Q}^t$ аппроксимирует решение ОДУ (Borkar, 2008):

$$\dot{Q}_i(s, a) = \bar{h}_i(s, a; \mathbf{Q}) - Q_i(s, a). \quad (18)$$

Неподвижная точка ОДУ — это $\bar{h}_i(s, a; \mathbf{Q}^*) = Q_i^*(s, a)$, то есть наша неподвижная точка из определения 6.2.

Если неподвижная точка ОДУ глобально асимптотически устойчива, то стохастическая аппроксимация (17) сходится к ней п.н. (Borkar, 2008, Theorem 2.2).

6.6. Устойчивость: оценка якобиана

Устойчивость неподвижной точки ОДУ определяется якобианом $J = \partial(\bar{h} - Q)/\partial \mathbf{Q}$. Нужно показать, что все его собственные значения имеют $\text{Re} < 0$.

Лемма 6.6 (Диагональные блоки). $\partial(\bar{h}_i - Q_i)/\partial Q_i$ имеет собственные значения с $\text{Re} \leq \gamma - 1 < 0$.

Доказательство. $\bar{h}_i$ зависит от Q_i через $\max_{a'} Q_i(s', a')$ в целевой функции. Производная: $\gamma \cdot P(s' | s, a) \cdot \mathbb{I}[a' = \arg \max]$. Вместе с $-Q_i$ это даёт спектральный радиус $\leq \gamma$, и собственные значения $\bar{h}_i - Q_i$ не превышают $\gamma - 1$. $\square$

Лемма 6.7 (Внедиагональные блоки). Для $j \in N_i$:

$$\left\| \frac{\partial \bar{h}_i}{\partial Q_j} \right\|_{\infty} \leq \frac{\gamma (b + c) k_i p_0 (1 - p_0)}{T (1 - \gamma)},$$

где $p_0 = 1/(1 + e^{ck_{\max}/T})$. Для $j \notin N_i \cup \{i\}$ производная равна нулю.

Доказательство. Цепочка зависимостей: $Q_j \rightarrow \pi_j \rightarrow P_i \rightarrow \bar{h}_i$.

$Q_j \rightarrow \pi_j$: $\pi_j(1 | s_j) = \sigma(\Delta Q_j(s_j)/T)$. Производная $|\partial \pi_j / \partial Q_j| \leq p_0(1 - p_0)/T$ (максимум сигмоиды — $1/(4T)$, но в неподвижной точке с $p_0 \ll 1/2$ это $p_0(1 - p_0)/T \ll 1/(4T)$).

$\pi_j \rightarrow P_i$: Агент j — один из k_i соседей. Изменение π_j на ϵ меняет распределение s_i^{t+1} на $d_{TV} \leq \epsilon$.

$P_i \rightarrow \bar{h}_i: |\delta \bar{h}_i| \leq \gamma \cdot d_{TV} \cdot \text{span}(V^*)/(1 - \gamma)$, где $\text{span}(V^*) \leq (b + c)k_i/(1 - \gamma)$.
Перемножая: влияние одного соседа j

$$\leq \frac{p_0(1 - p_0)}{T} \cdot 1 \cdot \frac{\gamma(b + c)k_i}{(1 - \gamma)^2}.$$

Но это оценка на один элемент Q-таблицы; суммируя по состояниям s_j , множитель остаётся тем же (максимум по s_j). $\square$

6.7. Основная теорема о сходимости

Теорема 6.8 (Сходимость). Рассмотрим n агентов на графе G , модель pp , Больцмановская политика с температурой $T > 0$, Q -learning с убывающими шагами α_t : $\sum_t \alpha_t = \infty$, $\sum_t \alpha_t^2 < \infty$. Определим:

$$\Lambda = \frac{\gamma(b + c)k_{\max}^2 p_0(1 - p_0)}{T(1 - \gamma)^2}, \quad p_0 = \frac{1}{1 + e^{ck_{\max}/T}}. \quad (19)$$

Если $\Lambda < 1$, то:

1. Неподвижная точка $\mathbf{Q}^*$ единственна.
2. Неподвижная точка ОДУ (18) глобально асимптотически устойчива.
3. $\mathbf{Q}^t \rightarrow \mathbf{Q}^*$ почти наверное.
4. В неподвижной точке $\Delta Q_i^*(s) = -C_i$ для всех i, s , и кооперация: $\hat{p} = n^{-1} \sum_i (1 + e^{C_i/T})^{-1}$.

Доказательство.

Пункт 1. По леммам 6.6–6.7 и теореме Гершгорина, отображение Φ является сжимающим с коэффициентом $\Lambda < 1$. Действительно, для каждого i :

Сумма модулей внедиагональных элементов по строке (влияние всех соседей) $\leq k_i \cdot \frac{\gamma(b+c)k_i p_0(1-p_0)}{T(1-\gamma)^2} \leq \Lambda \cdot (1 - \gamma)$.

Диагональный элемент: $\gamma - 1$. По Гершгорину, собственные значения лежат в круге с центром $\gamma - 1$ и радиусом $\leq \Lambda(1 - \gamma)$, то есть $\text{Re}(\lambda) \leq (\gamma - 1) + \Lambda(1 - \gamma) = (1 - \gamma)(\Lambda - 1) < 0$.

По теореме Банаха о сжимающем отображении: единственная неподвижная точка.

Пункт 2. Все собственные значения якобиана имеют $\text{Re} < 0$ (показано выше), значит неподвижная точка ОДУ асимптотически устойчива. Глобальность следует из того, что Φ — сжимающее на всём компакте.

Пункт 3. Проверяем условия теоремы Борбара (Borkar, 2008, Th. 2.2):

- Шаг: $\sum \alpha_t = \infty$, $\sum \alpha_t^2 < \infty$ — по условию.
- Шум ξ_i^t ограничен (награды и Q-значения ограничены).
- ОДУ имеет глобально устойчивую неподвижную точку (пункт 2).

Следовательно, $\mathbf{Q}^t \rightarrow \mathbf{Q}^*$ п.н.

Пункт 4. При $\Lambda < 1$ самосогласованная оценка (из раздела 5) даёт $|\Delta Q^*(s) - (-C_i)| = 0$: отклонение от нулевого приближения удовлетворяет $\delta \leq \Lambda \cdot \delta$, откуда $\delta = 0$. $\square$

6.8. Обсуждение условия $\Lambda < 1$

Условие $\Lambda < 1$ выполняется при:

- малом γ (близорукие агенты);
- большом T (гладкие, мало чувствительные к Q-значениям политики);
- малом k (разреженный граф).

При типичных экспериментальных параметрах ($\gamma = 0.9$, $k = 4$, $b = 3$, $c = 1$, $T = 1$) получаем $p_0 \approx 0.018$ и $\Lambda \approx 102 > 1$. Условие не выполнено.

Замечание 6.9 (Что означает $\Lambda \geq 1$). Это не означает, что система не сходится. Это означает, что наш метод доказательства недостаточно силён. При $\Lambda \geq 1$:

- может быть несколько неподвижных точек;
- система может сходиться к разным точкам в зависимости от начальных условий;
- могут существовать устойчивые циклы;
- формулы для $\hat{\rho}$ из теоремы 4.5 характеризуют одну из возможных неподвижных точек.

Замечание 6.10 (Почему экспериментально система всё же сходится). Несмотря на $\Lambda \geq 1$, в экспериментах наблюдается стабилизация $\rho(t)$. Причины:

1. Структура наград (5) такова, что $\Delta R_i = -C_i$ не зависит от действий соседей. «Цель» для каждого агента одна и та же вне зависимости от окружения — это сильный стабилизирующий фактор.
2. Фиксированный (не убывающий) α на практике не усиливает старые ошибки: каждое обновление вносит шум порядка $\alpha \cdot R_{\max}$, и Q-таблицы флуктуируют вокруг неподвижной точки, а не расходятся.

6.9. SARSA: аналогичная теорема

Теорема 6.11. Теорема 6.8 переносится на SARSA дословно, с заменой $\max_{a'} Q(s', a')$ на $\sum_{a'} \pi(a'|s') Q(s', a')$ в определении $\bar{h}_i$. Условие $\Lambda < 1$ остаётся тем же. Стационарная кооперация в нулевом приближении совпадает с Q-learning.

Доказательство. Структура доказательства идентична. Оператор Беллмана для фиксированной политики также сжимающий с коэффициентом γ . Лемма 4.2 доказана для обоих случаев. Оценки якобиана аналогичны (замена $\max$ на взвешенную сумму не увеличивает норму). $\square$

7. Monte Carlo режим

7.1. Почему базовая формула не переносится

При $k_{\text{anch}} = 1$ агент i участвует в раунде с вероятностью $(1 + k_i)/n$. Его награда зависит от того, кто выбран опорным.

Утверждение 7.1. В MC-режиме с $k_{\text{anch}} = 1$ разность ΔR_i^{MC} зависит от b и стратегий соседей, в отличие от одновременной игры. Формула $\hat{\rho} = n^{-1} \sum_i (1 + e^{C_i/T})^{-1}$ неприменима.

Доказательство. При $\text{anchor} = i$: $\Delta R_i = -C_i$ (как в одновременной игре). При $\text{anchor} = j \in N_i$: агент i участвует в попарной игре на ребре (i, j) , и его награда $g_i = bx_j - c \cdot 1 \cdot a$. Здесь $\Delta R_i^{(j)} = -c$, а слагаемое bx_j не сокращается, потому что для других anchor значение B_i другое. Усреднение по anchor -ам даёт ΔR_i^{MC} , зависящее от ожидаемых x_j , которые зависят от b . $\square$

8. Сводка результатов

Модель	ΔR_i	$\hat{\rho}$ (нулевое приближение)
pp, fp	$-c k_i$	$n^{-1} \sum_i (1 + e^{ck_i/T})^{-1}$
pf, ff	$-c$	$(1 + e^{c/T})^{-1}$

Граф	$\hat{\rho}_{pp/fp}$	$\hat{\rho}_{pf/ff}$
Звезда S_n	$\frac{1}{n+1} \left[\frac{n}{1+e^{c/T}} + \frac{1}{1+e^{cn/T}} \right]$	$(1 + e^{c/T})^{-1}$
k -регулярный	$(1 + e^{ck/T})^{-1}$	$(1 + e^{c/T})^{-1}$

Условие строгой сходимости (Q-learning и SARSA):

$$\Lambda = \frac{\gamma(b+c)k_{\max}^2 p_0(1-p_0)}{T(1-\gamma)^2} < 1.$$

9. Численные эксперименты

9.1. Настройки

Звезда: $N = 100$, $b \in \{1, \dots, 9\}$, $c = 1$, $k_{\text{anch}} = 1$, $\alpha = 0.2$, $\gamma \approx 0.99$, $T = 1.0$, до 15000 эпизодов, до 100 запусков.

Малый мир: $N = 50-100$, $k = 4$, $p_{\text{rewire}} = 0.1$, $T \in \{0.5, 1.0, 2.0\}$, $c = 1.0$, MC-режим с локальными гранулами.

9.2. Наблюдения

Эксперименты подтверждают: при малых γ кооперация хорошо согласуется с формулами теоремы 4.5; зависимость от b проявляется при $\gamma > 0.5$, что согласуется с поправкой теоремы 5.1; увеличение T повышает кооперацию; SARSA даёт несколько меньшую кооперацию, чем Q-learning.

10. Заключение

Сформулирована полная модель обучения с подкреплением на графе с четырьмя моделями наград, тремя режимами игры и двумя алгоритмами (Q-learning и SARSA).

Основные результаты: модели попарно эквивалентны по типу издержек (теорема 4.3, следствие 4.4); выведены явные формулы кооперации (теорема 4.5) для обоих алгоритмов; получена поправка, объясняющая зависимость от b (теорема 5.1); доказана строгая сходимость при $\Lambda < 1$ (теорема 6.8) с использованием ODE-метода стохастической аппроксимации; показано (утверждение 7.1), что в MC-режиме базовая формула неприменима.

Дальнейшие направления: улучшение оценки Λ (взвешенные нормы, учёт структуры графа), количественная оценка коэффициента чувствительности δ , расширение на графы Барабаши–Альберт.