

Q-learning динамика на графе: постановка, сходимость и сравнение с динамикой Константинова

1 Введение

Рассматривается динамика обучения с подкреплением в сетевых социальных дилеммах. Цель работы — формализовать модель, описать используемые правила обучения (Q-learning и SARSA), и сопоставить получаемую динамику кооперации с базовой динамикой Константинова. Отдельное внимание уделяется “гранулярному” монте-карло обновлению, когда за один раунд активна только локальная гранула узлов, что повышает стохастичность процесса и может поддерживать локальные кластеры кооператоров.

2 Формальная постановка модели

2.1 Граф и агенты

Пусть задан неориентированный граф $G = (V, E)$ с $|V| = n$. Матрица смежности $W = (w_{ij})$ определяет структуру взаимодействий, а множество соседей агента i обозначим N_i . Каждый агент выбирает стратегию $x_i \in \{0, 1\}$ (0 — Defect, 1 — Cooperate). В экспериментах используются графы: звезда, колесо и малый мир (Watts–Strogatz) с параметрами N , k и p .

2.2 Игра и выплаты

Игра задается типом наград и правилами взаимодействия. Система поддерживает четыре модели наград:

$$\text{pp: } g_i = b \sum_{j \in N_i} w_{ij} x_j - c x_i k_i, \quad (1)$$

$$\text{pf: } g_i = b \sum_{j \in N_i} w_{ij} x_j - c x_i, \quad (2)$$

$$\text{ff: } g_i = b \sum_{j \in N_i} \frac{w_{ij} x_j}{k_j} - c x_i, \quad (3)$$

$$\text{fp: } g_i = b \sum_{j \in N_i} \frac{w_{ij} x_j}{k_j} - c x_i k_i, \quad (4)$$

где k_i — степень узла i , b — выгода, c — издержки кооперации.

Реализованы три режима игры: (1) попарная игра на всех ребрах; (2a) Monte Carlo попарная игра на индуцированном подграфе; (2b) Monte Carlo игра “всеми wybranными игроками сразу”.

2.3 Базовая динамика (по Константинову)

В качестве базовой точки сравнения используется динамика Константинова. Основная метрика кооперации:

$$\rho(t) = \frac{1}{n} \sum_{i=1}^n x_i(t). \quad (5)$$

В экспериментах теоретические значения ρ для отдельных b используются как ориентиры на графиках.

3 Q-learning динамика

3.1 Определение состояния и Q-функции

Состояние агента i определяется числом кооперирующих соседей $s_i = \sum_{j \in N_i} x_j$ на релевантном подграфе. Q-функция хранится таблично: $Q_i(s, a)$.

3.2 Политика выбора действий

Используются две политики выбора действий:

$$\text{epsilon-greedy: } P(a) = \frac{\varepsilon}{|A|} + (1 - \varepsilon) [a = \arg \max_{a'} Q(s, a')], \quad (6)$$

$$\text{Boltzmann: } P(a) \propto \exp\left(\frac{Q(s, a)}{T}\right), \quad (7)$$

где T — температура, ε — параметр исследования.

3.3 Правило обновления

Для Q-learning:

$$Q_i(s_t, a_t) \leftarrow Q_i(s_t, a_t) + \alpha [r_{i,t} + \gamma \max_{a'} Q_i(s_{t+1}, a') - Q_i(s_t, a_t)]. \quad (8)$$

Для SARSA:

$$Q_i(s_t, a_t) \leftarrow Q_i(s_t, a_t) + \alpha [r_{i,t} + \gamma Q_i(s_{t+1}, a_{t+1}) - Q_i(s_t, a_t)]. \quad (9)$$

4 Сходимость

4.1 Формулировка результата

При стандартных условиях на α_t и достаточном исследовании табличный Q-learning сходится к оптимальным значениям Q-функции в стационарной среде. В многоагентной среде это условие нарушается, поэтому результат интерпретируется как эмпирическая динамика кооперации и поиск устойчивых режимов.

4.2 Доказательство

Доказательство опирается на стандартные факты теории стохастической аппроксимации и классические результаты по сходимости Q-learning в марковских средах при убывающем шаге обучения.

Сейчас докажем при одновременной игре всех агентов:

$$Q_i^*(s, a) = \mathbb{E}[R_i(a)] + \gamma \sum_{s'} P(s'|s, a) \max_{a'} Q_i^*(s', a')$$

В пределе $\tau \rightarrow \infty$ и при $\gamma < 1$:

$$Q_i^*(a) \approx R_i(s, a)$$

При бoльцмановской политике:

$$P(a) = \frac{e^{Q(s, a)/T}}{\sum_{a'} e^{Q(s, a')/T}}$$

$$P(a) \approx \sigma(\Delta Q(s, a)/T)$$

В случае награды pp:

$$\mathbb{E}[R_i(a)] = b \cdot \sum_{j \in N_i} \mathbb{E}[x_j] - c \cdot k_i \cdot a$$

$$\Delta Q_i^*(s) \approx (b \cdot \sum_{j \in N_i} \mathbb{E}[x_j] - c \cdot k_i \cdot 1) - (b \cdot \sum_{j \in N_i} \mathbb{E}[x_j] - c \cdot k_i \cdot 0) = -c \cdot k_i$$

$$P(a = 1) \approx \sigma(-c \cdot k_i/T) = \frac{1}{1 + e^{c \cdot k_i/T}}$$

$$\hat{\rho} \approx \frac{1}{n} \sum_{i=1}^n P(a_i = 1) = \frac{1}{n} \sum_{i=1}^n \frac{1}{1 + e^{c \cdot k_i/T}}$$

В случае $k_{anchors} = 1$:

$$\mathbb{E}[R_i(a)] = b \cdot \sum_{j \in N_i} (P(j \text{ is anchor}) + \sum_k [P(l \text{ is anchor}) * \omega_{k,j}]) - c \cdot k_i \cdot a$$

$$= b \cdot \sum_{j \in N_i} \left(\frac{1}{n} + \frac{1}{n} \sum_{l \in N_j} \omega_{l,j} \right) - c \cdot k_i \cdot a$$

$$\Delta Q_i^*(s) \approx b \cdot \sum_{j \in N_i} \left(\frac{1}{n} + \frac{1}{n} \sum_{l \in N_j} \omega_{l,j} \right) - c \cdot k_i - b \cdot \sum_{j \in N_i} \left(\frac{1}{n} + \frac{1}{n} \sum_{l \in N_j} \omega_{l,j} \right) = -c \cdot k_i$$

А значит опять

$$\hat{\rho} \approx \frac{1}{n} \sum_{i=1}^n P(a_i = 1) = \frac{1}{n} \sum_{i=1}^n \frac{1}{1 + e^{c \cdot k_i/T}}$$

4.3 Обсуждение и сравнение с динамикой Константинова

Если переходы состояния не зависят от действия агента, то разность Q-значений сводится к разности мгновенных наград, и стационарная вероятность кооперации аппроксимируется как

$$p_i \approx \frac{1}{1 + \exp\left(\frac{ck_i}{T}\right)}. \quad (10)$$

В многоагентной динамике предпосылка независимости нарушается, что приводит к наблюдаемой зависимости кооперации от параметра b .

5 Численные эксперименты

5.1 Настройки эксперимента

Используются графы типа звезда и малый мир. В экспериментах со звездообразным графом: $N = 100$, $b \in \{1, \dots, 9\}$, $c = 1$, $k_{anchors} = 1$, $\alpha = 0.2$, $\gamma \approx 0.99$, $T = 1.0$, число эпизодов — до 15000, число запусков — до 100.

В экспериментах на малом мире: N от 50 до 100, $k = 4$, $p = 0.1$, b фиксируется или варьируется, $T \in \{0.5, 1.0, 2.0\}$, $c = 1.0$, используется Monte Carlo режим с локальными гранулами.

5.2 Графики сходимости




Рис. 1: Звезда: динамика кооперации во времени.




Рис. 2: Звезда: финальная кооперация в зависимости от b .




Рис. 3: Малый мир: динамика кооперации при $T = 0.5, k_{anchors} = 1$.




Рис. 4: Малый мир: динамика кооперации при $T = 1.0, k_{anchors} = 1$.




Рис. 5: Малый мир: динамика кооперации при $T = 2.0, k_{anchors} = 1$.




Рис. 6: Малый мир: динамика кооперации (много запусков).




Рис. 7: Малый мир: финальная кооперация vs γ , $b = 3$, $T = 1.0$, $k_{anchors} = N$.




Рис. 8: Малый мир: финальная кооперация vs γ , $b = 5$, $T = 1.0$, $k_{anchors} = 1$.

6 Заключение

Сформулирована модель обучения на графе с несколькими режимами игры, реализованы Q-learning и SARSA с epsilon-greedy и Boltzmann политиками, описаны четыре вида наград. Эксперименты на звезде и малом мире показывают зависимость кооперации от b , T и γ и подтверждают, что локальное (гранулярное) обновление может поддерживать кооперативные кластеры. В дальнейшем планируется расширение на другие игры и адаптивный выбор гранул.