

Эффект ловушки в больцмановском Q-обучении матричных игр ИПУ РАН

Е.Е. Васильева^{1, 2} А.В. Леонидов^{1, 2} А.С. Титов^{1, 2}

¹ФИАН, Москва

²МФТИ, Долгопрудный

6 марта, 2025

Обучение с подкреплением




Рис.: Иллюстрация цикла действие-вознаграждение взаимодействия системы и агента

Обучение с подкреплением




Рис.: Иллюстрация цикла действие-вознаграждение взаимодействия системы и агента

Обучение с подкреплением

- В литературе существует две различающиеся ветви RL: в теоретико-игровой литературе и в литературе в сфере ИИ.
- В теоретико-игровом RL в постановке задачи всегда присутствует нестационарность среды. Для нестационарных сред не существует практически никаких теоретических результатов про сходимость обучения. Также важным аспектом является то, что когда мы говорим об играх с неизменяющейся во времени матрицей выплат, рассматриваются stateless-модели RL. Примером простейшего алгоритма RL может служить «cumulative payoff matching».
- Есть ряд других методов обучения, которые отличаются от RL наличием у агента не только выплат, но и некоторой другой информации об игре, например знание матрицы выплат или истории игры. Примерами других методов обучения являются:
 - ▶ Regret Matching
 - ▶ Fictitious play

Обучение с подкреплением

- В литературе по RL в сфере ИИ предлагается более экспериментальные результаты, а также приводится более широкий ряд моделей, например, методы RL, основанные на оценке ценности, методы, основанные на политике, методы, основанные на модели.
- Среди методов, основанных на оценке ценности, особый интерес представляют методы, основанные на временной разнице (TD-методы), которые включают в себя учет информации о «будущем», то есть у агента появляется стратегический взгляд вперед.
- Основной целью данной работы является применение TD-методов к теоретико-игровым задачам и исследование зависимости поведения агентов от вклада ожидаемой ценности в будущем в оценку ценности действия.

Связь принципа Беллмана и TD-методов в стационарной среде

- В методах обучения с подкреплением, основанных на оценке **ценности** пары состояние-действие, агент формирует функцию полезности – Q-функцию, на основе которой строит свою стратегию.
- Методика оценки Q-функции вдохновлена уравнением оптимальности Беллмана
- Пусть рассматривается обучение в **стационарной среде**. Обозначим $Q^*(s, a)$ функцию, характеризующую оптимальную ценность пары состояние-действие (s, a) при использовании принципа оптимальности Беллмана.
- Для $Q^*(\cdot)$ должно быть выполнено следующее уравнение:

$$Q^*(s, a) = \mathbb{E} [r(s, a) + \gamma \max_{a'} Q^*(s', a') | s, a] \quad (1)$$

- В играх с двумя игроками в качестве среды для игрока 1 выступают действия игрока 2. Поэтому среда **не является стационарной** и никаких утверждений о сходимости TD-методов в теоретико-игровых задачах нет.

Дилемма заключённых

	C	D
C	a, a	b, c
D	c, b	d, d

Таблица: Матрица выплат



Мы будем рассматривать Q-обучение агентов дилеммы заключённых: матричной игры с двумя игроками и двумя действиями C , D , с матрицей выплат, приведённой на таблице 1 со следующим ограничением на выплаты: $c > a > d > b$.

Стратегия $p(a) \forall a \in \{C, D\}$ является Logit QRE, если выполнено следующее условие:

$$p(a) = \frac{1}{1 - e^{\lambda(r(p(a)) - r(p(a)))}} \quad (2)$$

TD-методы

- В момент времени t игрок i ($i = 1, 2$) выбирает действие a_i одновременно с противником и независимо от него.
- Это действие выбирается в соответствии со стратегией $\pi_t^i = (p_t^i(C), p_t^i(D))$.
- Игроки получают вознаграждения r_t^i , взятые из матрицы выигрышей.
- В случае **Q-обучения** Q -значения обоих игроков обновляются в соответствии с правилом обновления Q -значений игрока i для действия $a \in \{C, D\}$ в момент времени $t \in \{1, \dots, T\}$:

$$Q_t^i(a) = Q_{t-1}^i(a) + \alpha \left(r_t^i(a) + \gamma \max_{a' \in \{C, D\}} Q_{t-1}^i(a') - Q_{t-1}^i(a) \right), \quad (3)$$

В момент времени $t = 0$ положим $Q_0^i(a) = 0 \forall i, a$.

- В случае **SARSA** в момент времени $t \in \{1, \dots, T\}$ агент выбирает действие a' в соответствии со своей политикой π_t^i и обновляет Q -значение для действия a по формуле:

$$Q_t^i(a) = Q_{t-1}^i(a) + \alpha (r_t^i(a) + \gamma Q_{t-1}^i(a') - Q_{t-1}^i(a)), \quad (4)$$

- Стратегия игрока i в момент времени t рассчитывается согласно распределению Больцмана, формально описываемому следующим выражением:

$$p_t^i(a) = \frac{e^{\beta Q_{t-1}^i(a)}}{e^{\beta Q_{t-1}^i(C)} + e^{\beta Q_{t-1}^i(D)}}, \quad a \in \{C, D\} \quad (5)$$

Предыдущие результаты

- В существующей литературе была найдена динамика больцмановского Q-обучения в терминах дифференциальных уравнений при $\gamma = 0$, то есть, она не учитывает использование информации об ожидаемой выгоде в будущих состояниях.
- Данная динамика является динамикой репликатора с дополнительным энтропийным членом.
- Было осознано, что при $\gamma = 0$ рассматриваемая система должна сходиться к QRE.

Стационарное состояние обучения

- **Предположение:** в пределе большого числа итераций обучения t политики игроков стабилизируются и, таким образом, для каждого игрока **среда становится стационарной**.
- Тогда из вида функции обновления Q-значений видно, что для заданной политики противника π_t^{-i} (локально) стационарные Q-значения $Q_t^*(a)$ игрока i удовлетворяют:

$$Q^{i*}(a) = \mathbb{E} [r(a) + \gamma \max_{a' \in \{C, D\}} Q^{i*}(a') | a], \quad a = C, D \quad (6)$$

Стационарное состояние обучения

- В случае больцмановского обучения без состояний $\max_{a' \in \{C, D\}} Q^*(a') = Q^*(D)$, то есть не зависит от a . Тогда имеем:

$$Q^*(a) - \gamma Q^*(D) = \mathbb{E}_{\pi_{-i}} r(a), \quad a = C, D \quad (7)$$

- Таким образом, в предположении о **неизменности политик** обоих игроков (= **стационарности сред** обоих игроков) получаем

$$\begin{cases} Q^{i*}(D) = \frac{\mathbb{E}_{\pi_t} r(D)}{1-\gamma} \\ Q^{i*}(C) = \frac{(1-\gamma)\mathbb{E}_{\pi_t} r(C) + \gamma\mathbb{E}_{\pi_t} r(D)}{1-\gamma} \end{cases}$$

Стационарное состояние обучения

- Стационарным значениям Q -функций в предположении о стационарности среды отвечают не меняющиеся во времени вероятности $p^{i*}(a)$, $a = C, D$ (и, соответственно, политики π^{i*}) игроков вида

$$p^{i*}(a) = \frac{\exp(\frac{\beta \mathbb{E}_{\pi-i*} r(a)}{1-\gamma})}{\exp(\frac{\beta \mathbb{E}_{\pi-i*} r(a)}{1-\gamma}) + \exp(\frac{\beta((1-\gamma)\mathbb{E}_{\pi-i*} r(a') + \gamma \mathbb{E}_{\pi-i*} r(a))}{1-\gamma})}, \quad (8)$$

где $a = C, D$, а $a' = D, C$.

Упростив, получим:

$$\begin{cases} p^{i*}(D) = \frac{1}{1 + \exp(\beta(\mathbb{E}_{\pi-i*} r(C) - \mathbb{E}_{\pi-i*} r(D)))} \\ p^{i*}(C) = \frac{1}{1 + \exp(\beta(\mathbb{E}_{\pi-i*} r(D) - \mathbb{E}_{\pi-i*} r(C)))} \end{cases} \quad (9)$$

Стационарное состояние обучения

$$\begin{cases} Q^{i*}(D) = \frac{\mathbb{E}_{\pi_t - i} r(D)}{1 - \gamma} \\ Q^{i*}(C) = \frac{(1 - \gamma) \mathbb{E}_{\pi_t - i} r(C) + \gamma \mathbb{E}_{\pi_t} r(D)}{1 - \gamma} \end{cases}$$
$$\begin{cases} p^{i*}(D) = \frac{1}{1 + \exp(\beta(\mathbb{E}_{\pi - i*} r(C) - \mathbb{E}_{\pi - i*} r(D)))} \\ p^{i*}(C) = \frac{1}{1 + \exp(\beta(\mathbb{E}_{\pi - i*} r(D) - \mathbb{E}_{\pi - i*} r(C)))} \end{cases}$$

- Стационарные Q-значения и вероятности зависят от стратегии второго игрока
- Стационарные Q-значения зависят от γ , а стационарные вероятности – нет
- В случае, когда $p^{1*}(a) = p^{2*}(a)$, стационарные стратегии игроков являются QRE.

Динамика обучения

Прирост Q-функции в момент времени t для действия a игрока i имеет следующий вид:

$$\Delta Q^i(a) = \begin{cases} \alpha(r + \gamma \max_{a'} Q_t^i(a') - Q_t^i(a)), & \text{если выбрано действие } a \\ 0, & \text{иначе} \end{cases} \quad (10)$$

В таком случае прирост вероятности имеет вид:

$$p_{t+1}(a) - p_t(a) = \begin{cases} p_t(a)(1 - p_t(a)) \frac{(e^{\beta \Delta Q_t(a)} - 1)}{1 + p_t(a)(e^{\beta \Delta Q_t(a)} - 1)} \\ p_t(a)(1 - p_t(a)) \frac{(1 - e^{\beta \Delta Q_t(b)})}{1 + (1 - p_t(a))(e^{\beta \Delta Q_t(b)} - 1)} \end{cases} \quad (11)$$

Режим ловушки

В обоих случаях знак знаменателя всегда положительный, тогда знак выражения $\Delta p_t^i(a)$ зависит только от числителя. В первом случае знак прироста $\Delta p_t(a)$ совпадает со знаком прироста $\Delta Q_t^i(a)$, во втором же случае знак прироста $\Delta p_a^i(a)$ противоположен знаку прироста $\Delta Q_t^i(b)$. Прирост $\Delta p_t^i(a)$ равен нулю при выполнении хотя бы одного из следующих трех условий:

$$\Delta p_t^i(a) = 0 \Leftrightarrow \left[\begin{array}{l} p_t^i(a) = 0 \\ 1 - p_t^i(a) = 0 \\ \left\{ \begin{array}{l} \Delta Q_t^i(a) = 0 \\ \Delta Q_t^i(b) = 0 \end{array} \right. \end{array} \right. \quad (12)$$

Режим преобладания стратегической эксплуатации (режим ловушки)




Рис.: Динамика вероятностей и Q-значений игроков. $T = 100000$,
 $\alpha = 0,01, \gamma = 0,9, \beta = 1$.

Режим ловушки

- Вероятность действия C в первые 1000 шагов обучения приходит в точку 0 и фиксируется в данном состоянии.
- Далее, траектория вероятности действия C игрока 2 выходит из 0 и приходит к некоторой смешанной стратегии. Эта стратегия является удовлетворяющей условию стационарности при условии, что противник имеет стратегию $\pi_t^i = (0, 1)$.
- В момент выхода из ловушки игрока 2 у игрока 1 резко растет Q -значение для действия D , тем самым, игрок «сильнее» застревает в ловушке.

Режим преобладания исследования (режим без ловушки)




Рис.: Динамика вероятностей и Q-значений игроков. $T = 100000$, $\alpha = 0,01, \gamma = 0, \beta = 1$.

Режим без ловушки

- Наблюдается стационарная динамика Q -значений.
- Вероятность выбора действия C обоих игроков флуктуирует около значения, соответствующего равновесию дискретного отклика.

Промежуточный режим




Рис.: Динамика вероятностей и Q-значений игроков в симуляции **дилеммы заключённых**. $T = 100000$, $\alpha = 0,01$, $\gamma = 0,7$, $\beta = 2$.

Промежуточный режим

- Начиная с некоторого момента времени графики вероятности и Q -значений приобретают периодический вид. Игроки не фиксируются ни в одной из точек.
- При этом графики и вероятностей, и обоих Q -значений двух игроков находятся в противофазе, что видно по рисунку.

Выход обоих игроков из ловушки




Рис.: Динамика вероятностей и Q-значений игроков в симуляции **дилеммы заключённых**. $T = 200000$, $\alpha = 0,1$, $\gamma = 0,9$, $\beta = 0,6$.

Выход обоих игроков из ловушки

- В данном эксперименте мы увеличили время обучения T и шаг обучения α , а также уменьшили параметр эксплуатации β , чтобы в симуляции наблюдался выход из ловушки обоих игроков.
- После выхода обоих агентов из ловушки траектории вероятностей флуктуируют около значения, соответствующего равновесию дискретного отклика.
- Обучение с большими значениями параметра α характеризуются существенной нестационарностью динамики. Поэтому наблюдается значительно более сложная картина.

Время в ловушке

Оценим характерное изменение вероятности выбора действия C , произошедшее в результате одного обновления $Q_t(C)$. Пусть, во первых, в момент времени C было выбрано действие C , и, во вторых, Q -значение для действия D близко к насыщению. Тогда

$$\lambda = \frac{p_C(t+1)}{p_C(t)} \approx e^{\beta \Delta Q_t(C)}, \quad (13)$$

где $\Delta Q_t(C)$ мы можем примерно оценить как

$$\Delta Q_t(C) \approx \alpha(\gamma \Delta Q_{t-1}(D) - \Delta Q_{t-1}(C)). \quad (14)$$

Время в ловушке

Для оценки, если $\tilde{p} = 0.01$, а выход из ловушки определяется достижением уровня вероятности $p^* = 0.1$, то потребуется порядка $K(\tilde{p}, p^*) \equiv K \approx 35$ раз выбрать стратегию C . Оценку ожидаемого времени $\tau^C(\tilde{p}, p^*)$, необходимого для перехода от вероятности $\tilde{p}$ к вероятности p^* , можно получить как оценку математического ожидания суммы геометрических случайных величин $\sum_{i=1}^K \tau_i^C$ с параметрами $\tilde{p}\lambda^{i-1}$ соответственно. В таком случае, имеем:

$$\mathbb{E}\tau^C(\tilde{p}, p^*) = \sum_{i=1}^K \mathbb{E}\tau_i^C = \sum_{i=1}^K \frac{1 - \tilde{p}\lambda^{i-1}}{\tilde{p}\lambda^{i-1}} = \frac{1}{\tilde{p}} \frac{1 - \frac{1}{\lambda^K}}{1 - \frac{1}{\lambda}} - K \quad (15)$$

Время в ловушке

- В серии из 100 симуляций на 100000 шагов только в 1 случае оба игрока не вышли из ловушки, а в 3 случаях оба агента вышли.
- В большинстве симуляций мы наблюдаем следующую картину: один из игроков выходит из ловушки, а второй остается в ней на длительный промежуток времени.
- В случае выхода соперника из ловушки, порядок значения вероятности действия C игрока, оставшегося в ловушке, значительно возрастает.
- Будем интересоваться временем, которое в ловушке проводит тот игрок, который из нее выходит (т.е. временем, когда наблюдается чистое равновесие Нэша).
- На рисунке на следующем слайде представлена гистограмма из 96 точек (из 100 симуляций были убраны «нетипичные», описанные выше).

Время в ловушке




Рис.: Гистограмма распределения времени в ловушке в серии из 100 симуляций Q-обучения дилеммы заключенных в случае выхода одного из агентов из ловушки. $T = 100000$, $\alpha = 0,01$, $\gamma = 0,9$, $\beta = 2$.

Время в ловушке

Среднее время по этим точкам составляет 33869 шагов, что соответствует порядку, полученному с помощью оценки выше.

Фазовая диаграмма




Рис.: Фазовая диаграмма режимов в плоскости β - γ для **Q-обучения дилеммы заключённых**. Зеленым цветом выделен режим «без ловушки», синим – «промежуточный» режим и красным – режим «ловушки». Зафиксированы параметры обучения $T = 100000$, $\alpha = 0,01$.

Фазовая диаграмма для SARSA




Рис.: Фазовая диаграмма режимов в плоскости β - γ для обучения **дилеммы заключённых** алгоритмом SARSA. Зеленым цветом выделен режим «без ловушки», синим – «промежуточный» режим и красным – режим «ловушки». Зафиксированы параметры обучения $T = 100000$, $\alpha = 0,01$.

Спасибо за внимание!