

Q-Learning на графах

Содержание

1 Обобщение дилеммы заключённых на N игроков

Рассмотрим классическую дилемму заключенного для двух игроков с двумя стратегиями: кооперация (C, cooperator) и предательство (D, defector). Стратегия кооперировать является альтруистической, тогда как стратегия предать — эгоистической. Матрица исходов в такой игре будет следующая:

	C	D
C	$b - c, b - c$	$-c, b$
D	$b, -c$	$0, 0$

В такой игре кооператор несет издержки c , оппонент кооператора получает награду b . У эгоиста издержек нет. Заметим, что награда игрока явно зависит только от поведения оппонента, тогда как своя стратегия играет неважную роль.

Стратегии выбираются одновременно и без знания о прошлом. В дилемме заключенного при такой постановке должно существовать единственное равновесие Нэша — (D, D) . Для соблюдения этого правила введем ограничения на параметры награды:

$$0 < c < b$$

Без ограничения общности можно считать, что $c = 1$.

Так как большинство процессов в мире повторяются, то и игры имеет смысл рассматривать с повторами. Такие игры называются эволюционными. Одной из первых исследованных эволюционных игр стала итерационная дилемма заключенного. Заметим, что при повышении параметра награды b соблазн стать предателем уменьшается. В этом и заключается одно из ключевых различий одношаговой и многошаговой игры — в одношаговой игре при любом b равновесием всегда будет всеобщий эгоизм, тогда как в многошаговой это не всегда так.

Теперь переформулируем постановку дилеммы заключенного через представление взаимодействия агентов в виде игры на графе. В вершинах графа будут размещаться агенты, а их взаимодействие происходить по ребрам этого графа.

Введем обозначения:

- размер графа — n ;
- матрица смежности

$$w_{ij} = \begin{cases} 1, & i \sim j \\ 0, & \text{иначе} \end{cases}$$

- степень i -го агента

$$k_i = \sum_j w_{ij}$$

- стратегия i -го агента

$$x_i = \begin{cases} 1, & i\text{-й агент — кооператор} \\ 0, & i\text{-й агент — эгоист} \end{cases}$$

- N_i — множество соседей i -го агента;
- $g(x_i)$ — награда i -го агента;
- x_i^t — стратегия i -го агента в момент времени t .

Дилеммой заключенного или парной игрой в такой постановке будет игра на графе из двух вершин ($n = 2$), соединенных одним ребром. Тогда дилемму заключенного можно переписать следующим образом:

$$g(x_1) = bx_2 - cx_1, \quad g(x_2) = bx_1 - cx_2.$$

В данной работе мы будем рассматривать обобщения на N игроков дилеммы заключенных, в которых участник игры имеет две стратегии — произвести награду b , либо не производить. В случае, когда он выбирает производство, он несет издержки c и является кооператором. Если агент ничего не производит, то он не несет никаких издержек и является эгоистом. То, что участник производит, равномерно распределяется между всеми его соседями. Количество производимой награды и размер издержек определяется их типом и степенью агента. Награды (b) и затраты (c) можно разделить на два вида — пропорциональные («р») числу связей агента и фиксированные («ф»). Тогда образуются четыре различных типа игры: «рр» (пропорциональные награды, пропорциональные издержки), «pf» (пропорциональные награды, фиксированные издержки), «ff» (фиксированные награды, фиксированные издержки) и «fp» (фиксированные награды, пропорциональные издержки).

Формулы для награды i -го агента в системе, представленной графом, следующие:

«рр» игра

$$g(x_i) = b \sum_j w_{ij} x_j - cx_i \sum_j w_{ij} = b \sum_j w_{ij} x_j - cx_i k_i \quad (2)$$

«pf» игра

$$g(x_i) = b \sum_j w_{ij} x_j - cx_i \quad (3)$$

«ff» игра

$$g(x_i) = b \sum_j w_{ij} \frac{x_j}{k_j} - cx_i \quad (4)$$

«fp» игра

$$g(x_i) = b \sum_j w_{ij} \frac{x_j}{k_j} - cx_i \sum_j w_{ij} = b \sum_j w_{ij} \frac{x_j}{k_j} - cx_i k_i \quad (5)$$

Можно видеть, что обобщенная N -дилемма заключенного без стохастики (1) совпадает с игрой типа «рр» (2).

Одним из необходимых условий обобщения правил наград является совпадение правил непарной игры с классической дилеммой заключенного в случае игры на одном ребре (то есть парной игры). Это условие выполняется для всех введенных выше непарных правил.

Заметим, что игра с общественным благом является частным случаем игры «pf», а дилемма добровольца — частным случаем игры «ff».

Эти правила можно с легкостью комбинировать, создавая для каждого агента свой тип игры.

2 Описание алгоритма

Алгоритм Q-обучения ? относится к классу алгоритмов обучения с подкреплением, основанных на оценке ценности пары состояние-действие (value-based methods, см. ?. В методах обучения с подкреплением, относящихся к данному классу, агенты строят свою стратегию на основе величин Q-значений, оценивающих ценность пары состояние-действие. В рассматриваемом случае повторяющихся матричных игр, для которых матрица выплат не меняется от шага к шагу, мы, тем самым, имеем дело с системой с одним состоянием.

Рассматриваемый алгоритм обучения описывается следующим образом. В момент времени t игрок i ($i = 1, \dots, n$) выбирает действие $a_i^{(t)} \in \{C, D\}$ одновременно с противником и независимо от него. Это действие выбирается в соответствии с политикой $\pi_i^{(t)} = (p_i^{(t)}(C), p_i^{(t)}(D))$, где $p_i^{(t)}(a_i)$ — вероятность выбора действия $a_i \in \{C, D\}$ на момент времени t . Игроки получают вознаграждения $r_i^{(t)} = r_i^{(t)}(a_i, a_{-i})$, взятые из матрицы выигрышей, зависящие от выбранного действия каждым из игроков. Далее Q-значения всех игроков ($i = 1, \dots, n$) обновляются в соответствии правилом обновления Q-значений игрока i для действия $a_i \in \{C, D\}$ в момент времени $t \in \{1, \dots, t^{max}\}$:

$$Q_i^{(t+1)}(a_i) = \begin{cases} Q_i^{(t)}(a_i) + \alpha \left(r_i^{(t)}(a_i, a_{-i}^{(t)}) + \gamma \max_{a' \in \{C, D\}} Q_i^{(t)}(a') - Q_i^{(t)}(a_i) \right), \\ \text{если } a_i = a_i^{(t)} \text{ (т.е., было выбрано действие } a_i) \\ Q_i^{(t)}(a_i), \text{ в противном случае,} \end{cases} \quad (1)$$

где $a_{-i}^{(t)}$ — выбор оппонента в момент времени t . Таким образом, для каждого игрока в каждый момент времени происходит обновление только одного из двух значений $Q_i^{(t)}(C)$ или $Q_i^{(t)}(D)$, соответствующего текущему выбору игрока.

В момент времени $t = 0$ положим $Q_i^{(0)}(a_i) = 0 \forall i = 1, 2, a_i \in \{C, D\}$. В настоящей работе рассматривается больцмановское Q-обучение, предполагающее, что политика игрока i в момент времени t рассчитывается согласно распределению

$$p_i^{(t)}(a_i) = \frac{e^{\beta Q_i^{(t)}(a_i)}}{e^{\beta Q_i^{(t)}(C)} + e^{\beta Q_i^{(t)}(D)}}, \quad a_i \in \{C, D\} \quad (2)$$

где $\beta = \frac{1}{T}$ — параметр, отражающий интенсивность исследовательского поведения агента. Большие значения T и, соответственно, малые значения β , отвечают интенсивному исследованию игроками пространства стратегий, в том числе — неоптимальных с точки зрения текущего накопленного опыта. И наоборот, при $T \rightarrow 0$ ($\beta \rightarrow \infty$) при выборе стратегии игроки жадно следуют своим текущим оценкам Q-значений.

3 Особенности постановки экспериментов

Далее везде рассматривается класс игр pp . При этом в награде всем игрокам выдается бонус $+1$, чтобы все числа матрицы выплат стали положительными. То есть формула выплат каждого игрока имеет вид:

$$r_i^{(t)}(a_i, a_{-i}) = g(a_i) = b \sum_j w_{ij} a_j^{(t)} - c a_i^{(t)} k_i + 1$$

Были выбраны параметры $b = 2$, $c = 1$.

4 Результаты

Параметры экспериментов: $\alpha = 0.01$, $\beta = 0.5$, $T_{it} = 10^6$ итераций.

4.0.1 Клика




Рис. 1: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 2: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 3: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 4: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 5: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.0.2 Линия




Рис. 6: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 7: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 8: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 9: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 10: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.1 Граф с 4 вершинами

4.1.1 Клика




Рис. 11: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 12: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 13: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 14: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 15: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.1.2 Линия




Рис. 16: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 17: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 18: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 19: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 20: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.1.3 Звезда




Рис. 21: Динамика вероятности выбора действия S $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 22: Динамика вероятности выбора действия S $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 23: Динамика вероятности выбора действия S $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 24: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 25: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.1.4 Цикл




Рис. 26: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 27: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 28: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 29: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 30: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.1.5 Колесо




Рис. 31: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 32: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 33: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 34: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 35: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

lain]Граф с 3

4.2 Граф с 3 вершинами

4.2.1 Клика




Рис. 36: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 37: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 38: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 39: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 40: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.2.2 Линия




Рис. 41: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 42: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 43: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 44: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 45: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.3 Граф с 4 вершинами

4.3.1 Клика




Рис. 46: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 47: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 48: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 49: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 50: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.3.2 Линия




Рис. 51: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 52: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 53: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 54: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 55: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.3.3 Звезда




Рис. 56: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 57: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 58: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 59: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 60: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.3.4 Цикл




Рис. 61: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 62: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 63: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 64: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 65: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

4.3.5 Колесо




Рис. 66: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.0$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 67: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.3$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 68: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.5$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 69: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.7$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.




Рис. 70: Динамика вероятности выбора действия C $p_i^{(t)}(C)$ и Q -значений $Q_i^{(t)}(a)$ алгоритма Q -обучения при $\gamma = 0.9$. $T = 1000000$, $\alpha = 0.01$, $\beta = 0.5$.

lain