

Ловушки дефекции в многоагентном Q-обучении: Стохастическая теория и численная верификация

Проект RL_GameTheory

4 февраля 2026 г.

Аннотация

Рассматривается феномен *ловушек дефекции* в многоагентном Q-обучении с Boltzmann-политикой в обобщённой дилемме заключённого. Показано, что при малом шаге обучения α система демонстрирует метастабильное дефектное равновесие, выход из которого возможен только за счёт стохастических флуктуаций.

Получена асимптотическая формула для среднего времени выхода из ловушки в пределе $\alpha \rightarrow 0$:

$$\mathbb{E}[\tau_{\text{exit}}] \sim \exp\left(\frac{\kappa \Delta^2}{\alpha \Sigma^2(x^*)}\right),$$

где κ — локальная сила возврата к равновесию, Δ — расстояние до границы ловушки, $\Sigma^2(x^*)$ — дисперсия стохастического шума в равновесии.

1 Введение

Многоагентное обучение с подкреплением в играх приводит к сложной стохастической динамике, включающей метастабильные состояния и чрезвычайно медленную сходимость. Одним из наиболее устойчивых феноменов являются *ловушки дефекции* — длительное пребывание системы в состоянии почти полной дефекции, несмотря на наличие более выгодных кооперативных исходов.

В данной работе мы даём строгую стохастическую теорию возникновения и разрушения таких ловушек в многоагентном Q-обучении с Boltzmann-политикой и выводим экспоненциальную асимптотику времени выхода из ловушки.

2 Модель

2.1 Обобщённая дилемма заключённого

Рассматривается n -игровая линейная игра общественных благ.

Определение 1. Каждый игрок выбирает действие $a_i \in \{C, D\}$. Пусть

$$k = \sum_{i=1}^n \mathbf{1}_{\{a_i=C\}}$$

— число кооператоров. Выплата игрока i равна

$$u_i = \begin{cases} \frac{bk}{n} - c, & a_i = C, \\ \frac{bk}{n}, & a_i = D, \end{cases}$$

где $b > 0$ — выгода от кооперации, $c > 0$ — её стоимость.

Утверждение 1. *Игра является дилеммой заключённого при условии*

$$\frac{b}{n} < c < b.$$

2.2 Q-обучение с Boltzmann-политикой

Каждый агент поддерживает значения $Q_t(C), Q_t(D)$ и выбирает действия согласно Boltzmann-политике

$$\pi_t(a) = \frac{e^{\beta Q_t(a)}}{e^{\beta Q_t(C)} + e^{\beta Q_t(D)}}, \quad \beta > 0.$$

Обновление Q-значений имеет вид

$$Q_{t+1}(a) = \begin{cases} Q_t(a) + \alpha(r_t + \gamma \max_{a'} Q_t(a') - Q_t(a)), & a = a_t, \\ Q_t(a), & \text{иначе.} \end{cases}$$

3 Редукция динамики

В данном разделе мы строго выводим одномерную стохастическую динамику, описывающую эволюцию многоагентного Q-обучения в симметричном режиме.

3.1 Редукция к разности Q-значений

Лемма 1 (Редукция к разности Q-значений). *В симметричном режиме многоагентного Q-обучения динамика системы полностью описывается одномерным процессом*

$$\Delta Q_t := Q_t(C) - Q_t(D).$$

Вероятность выбора действия C в момент времени t равна

$$p_t = \sigma(\beta \Delta Q_t), \quad \sigma(x) = \frac{1}{1 + e^{-x}}.$$

Доказательство. По определению Boltzmann-политики, вероятность выбора действия C равна

$$\pi_t(C) = \frac{e^{\beta Q_t(C)}}{e^{\beta Q_t(C)} + e^{\beta Q_t(D)}}.$$

Вынесем множитель $e^{\beta Q_t(D)}$ из знаменателя:

$$\pi_t(C) = \frac{e^{\beta(Q_t(C) - Q_t(D))}}{1 + e^{\beta(Q_t(C) - Q_t(D))}} = \sigma(\beta \Delta Q_t).$$

Таким образом, стратегия агента зависит от Q-значений только через их разность ΔQ_t . Абсолютный сдвиг $Q_t(C) \mapsto Q_t(C) + K$, $Q_t(D) \mapsto Q_t(D) + K$ не влияет ни на стратегию, ни на будущие обновления.

Так как все агенты симметричны и рассматривается симметричное подпространство состояний, эволюция системы редуцируется к динамике одной скалярной величины ΔQ_t . $\square$

3.2 Стохастическая аппроксимация

Обозначим через $\mathcal{F}_t$ состояние системы, порождённое процессом Q-обучения, то есть $\mathcal{F}_t$ содержит всю информацию о действиях, наградах и Q-значениях до момента t включительно.

Лемма 2 (Стохастическая аппроксимация). *Существует измеримая функция $F : \mathbb{R} \rightarrow \mathbb{R}$ и последовательность случайных величин $\{\eta_t\}_{t \geq 0}$, такие что*

$$\Delta Q_{t+1} = \Delta Q_t + \alpha F(\Delta Q_t) + \alpha \eta_t,$$

где выполнены условия:

$$\begin{aligned} \mathbb{E}[\eta_t \mid \mathcal{F}_t] &= 0, \\ \sup_t \mathbb{E}[\eta_t^2 \mid \mathcal{F}_t] &< \infty. \end{aligned}$$

Доказательство. По правилу Q-обновления имеем:

$$Q_{t+1}(a) = Q_t(a) + \alpha \mathbf{1}_{\{a_t=a\}}(r_t + \gamma \max_{a'} Q_t(a') - Q_t(a)), \quad a \in \{C, D\}.$$

Вычитая обновление для D из обновления для C , получаем:

$$\Delta Q_{t+1} - \Delta Q_t = \alpha \xi_t,$$

где случайная величина ξ_t равна

$$\xi_t := \mathbf{1}_{\{a_t=C\}}(r_t + \gamma \max_{a'} Q_t(a') - Q_t(C)) - \mathbf{1}_{\{a_t=D\}}(r_t + \gamma \max_{a'} Q_t(a') - Q_t(D)).$$

Определим детерминированный дрейф как условное математическое ожидание:

$$F(x) := \mathbb{E}[\xi_t \mid \Delta Q_t = x].$$

Далее введём шумовую составляющую:

$$\eta_t := \xi_t - F(\Delta Q_t).$$

По построению имеем:

$$\mathbb{E}[\eta_t \mid \mathcal{F}_t] = \mathbb{E}[\xi_t \mid \mathcal{F}_t] - F(\Delta Q_t) = 0,$$

то есть η_t является мартингальной разностью относительно фильтрации $\{\mathcal{F}_t\}$.

Так как награды r_t по предположению имеют конечную дисперсию, а Q-значения остаются конечными при фиксированном шаге обучения, существует константа $C < \infty$ такая, что

$$\mathbb{E}[\eta_t^2 \mid \mathcal{F}_t] \leq C \quad \text{для всех } t.$$

Следовательно, процесс ΔQ_t является стохастической аппроксимацией с шагом α , детерминированным дрейфом F и мартингальным шумом η_t . $\square$

Замечание 1. При формальном пределе $\eta_t \equiv 0$ получается детерминированное рекуррентное соотношение, которое сходится к устойчивому дефектному равновесию. Таким образом, существование ловушки дефекции является исключительно стохастическим эффектом.

4 Детерминированный дрейф в дефектной области

В этом разделе мы явно вычисляем функцию дрейфа $F(x)$, определённую как условное математическое ожидание приращения разности Q-значений, в области $\Delta Q < 0$. Все вычисления являются точными и не используют асимптотических приближений.

4.1 Выигрыши и TD-ошибки

Рассмотрим фиксированного агента i . Пусть K_{-i} — случайная величина, равная числу кооператоров среди остальных $n - 1$ агентов.

При фиксированном значении k выигрыши агента i равны:

$$r_C(k) = \frac{b(k+1)}{n} - c + \text{offset}, \quad r_D(k) = \frac{bk}{n} + \text{offset}.$$

Для действий $a \in \{C, D\}$ определим TD-ошибки:

$$TD_a = r_a(K_{-i}) + \gamma \max(Q^C, Q^D) - Q^a.$$

4.2 Инкремент разности Q-значений

Определим разность Q-значений:

$$\Delta Q(m) := Q^C(m) - Q^D(m).$$

Определим нормированный инкремент:

$$\xi(m) := \frac{\Delta Q(m+1) - \Delta Q(m)}{\alpha}.$$

Лемма 3 (Точное выражение для инкремента). *Выполняется:*

$$\xi(m) = \begin{cases} TD_C, & \text{если } a_i(m) = C, \\ -TD_D, & \text{если } a_i(m) = D. \end{cases}$$

Доказательство. Если $a_i(m) = C$, то обновляется только Q^C :

$$\Delta Q(m+1) - \Delta Q(m) = \alpha TD_C.$$

Если $a_i(m) = D$, то обновляется только Q^D :

$$\Delta Q(m+1) - \Delta Q(m) = -\alpha TD_D.$$

Деление на α даёт требуемый результат. □

4.3 Определение дрейфа

Определим функцию дрейфа как

$$F(x) := \mathbb{E}[\xi(m) \mid \Delta Q(m) = x].$$

По закону полного ожидания:

$$F(x) = \sigma(\beta x) \mathbb{E}[TD_C \mid \Delta Q = x] - (1 - \sigma(\beta x)) \mathbb{E}[TD_D \mid \Delta Q = x].$$

4.4 Средняя разность выигрышей

Лемма 4 (Средняя разность выигрышей). *Выполняется:*

$$\mathbb{E}[r_C(K_{-i}) - r_D(K_{-i})] = \frac{b}{n} - c.$$

Доказательство. Для любого k :

$$r_C(k) - r_D(k) = \left(\frac{b(k+1)}{n} - c \right) - \frac{bk}{n} = \frac{b}{n} - c.$$

Следовательно, это равенство сохраняется и после взятия математического ожидания по распределению K_{-i} . $\square$

4.5 Дрейф в дефектной области и разложение на главный вклад и остаток

Рассмотрим шаг алгоритма m и зафиксируем значение

$$x := \Delta Q(m) = Q^C(m) - Q^D(m).$$

Мы будем работать в дефектной области

$$x < 0, \quad Q^D(m) > Q^C(m),$$

в которой выполняется

$$\max\{Q^C(m), Q^D(m)\} = Q^D(m).$$

4.5.1 TD-ошибки

Для действий $a \in \{C, D\}$ TD-ошибки имеют вид

$$TD_a = r_a(K_{-i}) + \gamma Q^D(m) - Q^a(m),$$

где K_{-i} — число кооператоров среди остальных агентов.

Следовательно,

$$TD_C = r_C + \gamma Q^D - Q^C, \tag{1}$$

$$TD_D = r_D + (\gamma - 1)Q^D. \tag{2}$$

4.5.2 Определение дрейфа

Определим шумовую переменную

$$\xi(m) = \begin{cases} TD_C, & a_i(m) = C, \\ -TD_D, & a_i(m) = D. \end{cases}$$

Детерминированный дрейф задаётся как

$$F(x) := \mathbb{E}[\xi(m) \mid \Delta Q(m) = x].$$

Лемма 5 (Закон полного ожидания по действию). *При фиксированном значении $\Delta Q(m) = x$ выполняется*

$$F(x) = \sigma(\beta x) \mathbb{E}[TD_C \mid x] - (1 - \sigma(\beta x)) \mathbb{E}[TD_D \mid x]. \tag{3}$$

Доказательство. Условно на $\Delta Q(m) = x$ действие агента $a_i(m)$ принимает значения C и D с вероятностями $\sigma(\beta x)$ и $1 - \sigma(\beta x)$ соответственно. По закону полного математического ожидания по разбиению $\{a_i(m) = C\} \cup \{a_i(m) = D\}$ получаем (3). $\square$

4.5.3 Точное выражение для дрейфа

Подставляя (1)–(2) в (3), получаем

$$F(x) = \sigma(\beta x)(\mathbb{E}[r_C] + \gamma Q^D - Q^C) - (1 - \sigma(\beta x))(\mathbb{E}[r_D] + (\gamma - 1)Q^D). \quad (4)$$

Используя тождество $Q^C = Q^D + x$, справедливое при условии $\Delta Q(m) = x$, преобразуем (4) к виду

$$F(x) = \sigma(\beta x)(\mathbb{E}[r_C] + \mathbb{E}[r_D]) - \mathbb{E}[r_D] - \sigma(\beta x)x + (\gamma - 1)Q^D(2\sigma(\beta x) - 1). \quad (5)$$

Формула (5) является *точным* выражением для дрейфа в дефектной области.

4.5.4 Выделение главного вклада

В игре общественных благ выполняется

$$\mathbb{E}[r_C - r_D] = \frac{b}{n} - c,$$

и потому

$$\mathbb{E}[r_C] + \mathbb{E}[r_D] = \left(\frac{b}{n} - c\right) + 2\mathbb{E}[r_D].$$

Определим главный вклад дрейфа как

$$F_{\text{main}}(x) := \sigma(\beta x) \left(\frac{b}{n} - c - x\right). \quad (6)$$

Оставшуюся часть определим как остаток:

$$R(x) := F(x) - F_{\text{main}}(x).$$

Явно из (5) и (6) получаем

$$R(x) = (\gamma - 1)Q^D(2\sigma(\beta x) - 1) + 2\sigma(\beta x)\mathbb{E}[r_D] - \mathbb{E}[r_D]. \quad (7)$$

4.5.5 Оценка остатка

Лемма 6 (Ограниченность остатка). *Пусть параметры β, γ фиксированы, а выигрыши имеют конечное математическое ожидание. Тогда существует константа $C < \infty$, такая что*

$$|R(x)| \leq C \quad \text{для всех } x < 0.$$

Доказательство. Функция $\sigma(\beta x)$ принимает значения в интервале $(0, 1)$. Следовательно,

$$|2\sigma(\beta x) - 1| \leq 1.$$

Так как $Q^D(m)$ фиксировано на шаге m , а $\mathbb{E}[r_D]$ конечно, каждое слагаемое в (7) ограничено по модулю. Сумма ограниченных слагаемых также ограничена. $\square$

Замечание 2. Остаток $R(x)$ не содержит множителей порядка $1/\alpha$ и не масштабируется при $\alpha \rightarrow 0$. Поэтому при анализе асимптотики времени выхода из ловушки он не влияет на ведущий экспоненциальный порядок.

4.6 Равновесие

Теорема 1 (Дефектное равновесие). Если $\frac{b}{n} < c$, то уравнение

$$F_{\text{main}}(x) = 0$$

имеет единственное решение

$$x^* = \frac{b}{n} - c < 0.$$

Доказательство. Так как $\sigma(\beta x) > 0$ для всех x , равенство $F_{\text{main}}(x) = 0$ эквивалентно

$$\frac{b}{n} - c - x = 0,$$

откуда следует $x^* = \frac{b}{n} - c$. □

Определение 2 (Сила возврата). Определим

$$\kappa := -F'_{\text{main}}(x^*) = \sigma(\beta x^*).$$

5 Непрерывное приближение динамики

В данном разделе мы показываем, что при малом шаге обучения α дискретная стохастическая динамика разности Q-значений

$$\Delta Q(m)$$

может быть аппроксимирована детерминированной непрерывной динамикой на временных масштабах порядка $1/\alpha$. Полученное приближение описывает усреднённое поведение системы на конечных временных интервалах.

5.1 Общий вид дискретной динамики

Рассмотрим одномерный дискретный процесс вида

$$X_{m+1} = X_m + \alpha F(X_m) + \alpha \eta(m), \tag{8}$$

где:

- $F : \mathbb{R} \rightarrow \mathbb{R}$ — детерминированная функция;
- $\{\eta(m)\}$ — последовательность случайных величин, удовлетворяющая условию нулевого условного среднего:

$$\mathbb{E}[\eta(m) \mid \mathcal{F}_m] = 0;$$

- условные вторые моменты равномерно ограничены:

$$\sup_m \mathbb{E}[\eta(m)^2 \mid \mathcal{F}_m] < \infty.$$

В предыдущем разделе было показано, что процесс

$$X_m = \Delta Q(m)$$

имеет именно такой вид, где функция F задаётся формулой (5), а $\eta(m)$ представляет собой центрированный стохастический шум.

Замечание. В силу структуры модели функция F является непрерывной и локально липшицевой на любом компакте, содержащем значения $\Delta Q(m)$ на конечном временном интервале. Это следует из гладкости сигмоидальной функции $\sigma(\beta x)$ и из того, что условные математические ожидания наград $\mathbb{E}[r_C]$, $\mathbb{E}[r_D]$ являются гладкими функциями вероятности кооперации, а значит, гладкими функциями $x = \Delta Q$.

5.2 Масштабирование времени

Для анализа поведения процесса на больших временах введём новое непрерывное время

$$s := \alpha t$$

и определим интерполированный процесс

$$X^{(\alpha)}(s) := \Delta Q(\lfloor s/\alpha \rfloor).$$

Таким образом, $X^{(\alpha)}(s)$ является кусочно-постоянной функцией, которая описывает дискретную динамику $\Delta Q(m)$ на временной шкале порядка $1/\alpha$.

5.3 Предел при исчезающем шаге обучения

Теорема 2 (Детерминированный предельный процесс). *Пусть $\alpha \rightarrow 0$. Тогда для любого $T > 0$ существует функция $x : [0, T] \rightarrow \mathbb{R}$ такая, что процесс $X^{(\alpha)}(s)$ сходится к $x(s)$ по вероятности, равномерно по $s \in [0, T]$, и функция $x(s)$ удовлетворяет интегральному уравнению*

$$x(t) - x(s) = \int_s^t F(x(u)) du, \quad 0 \leq s < t \leq T.$$

В частности, функция x дифференцируема и является решением обыкновенного дифференциального уравнения

$$\frac{dx}{ds} = F(x), \quad x(0) = \lim_{\alpha \rightarrow 0} X^{(\alpha)}(0).$$

Доказательство. Зафиксируем $s \geq 0$ и $\Delta s > 0$. Рассмотрим приращение интерполированного процесса:

$$\begin{aligned} X^{(\alpha)}(s + \Delta s) - X^{(\alpha)}(s) &= \sum_{k=\lfloor s/\alpha \rfloor}^{\lfloor (s+\Delta s)/\alpha \rfloor - 1} \alpha F(X_k) + \sum_{k=\lfloor s/\alpha \rfloor}^{\lfloor (s+\Delta s)/\alpha \rfloor - 1} \alpha \eta(k) \\ &=: S_1^{(\alpha)}(s, \Delta s) + S_2^{(\alpha)}(s, \Delta s). \end{aligned}$$

Детерминированный член. Заметим, что число слагаемых в сумме $S_1^{(\alpha)}$ равно

$$N_\alpha = \lfloor (s + \Delta s)/\alpha \rfloor - \lfloor s/\alpha \rfloor = \frac{\Delta s}{\alpha} + O(1).$$

Для каждого k положим $u_k := \alpha k$. Тогда $u_k \in [s - \alpha, s + \Delta s]$, и соответствующий вклад равен

$$\alpha F(X_k) = \alpha F(X^{(\alpha)}(u_k)).$$

Следовательно, сумма $S_1^{(\alpha)}$ является римановой суммой для интеграла

$$\int_s^{s+\Delta s} F(X^{(\alpha)}(u)) du,$$

с погрешностью порядка $O(\alpha)$, связанной с округлением границ интервала и кусочно-постоянной интерполяцией. Эта погрешность стремится к нулю при $\alpha \rightarrow 0$, равномерно по s на конечных интервалах.

Случайный член. Рассмотрим сумму

$$S_2^{(\alpha)}(s, \Delta s) = \sum_{k=\lfloor s/\alpha \rfloor}^{\lfloor (s+\Delta s)/\alpha \rfloor - 1} \alpha \eta(k).$$

Используя свойство нулевого условного среднего и итеративное применение свойства условного ожидания, получаем

$$\mathbb{E}[S_2^{(\alpha)}(s, \Delta s) \mid \mathcal{F}_{\lfloor s/\alpha \rfloor}] = 0.$$

Для условной дисперсии имеем:

$$\mathbb{E}[(S_2^{(\alpha)}(s, \Delta s))^2 \mid \mathcal{F}_{\lfloor s/\alpha \rfloor}] = \sum_k \alpha^2 \mathbb{E}[\eta(k)^2 \mid \mathcal{F}_k],$$

где перекрёстные члены исчезают, поскольку $\eta(k)$ имеет нулевое условное среднее относительно $\mathcal{F}_k$. Так как число слагаемых порядка $\Delta s/\alpha$, а условные дисперсии равномерно ограничены, получаем оценку

$$\mathbb{E}[(S_2^{(\alpha)}(s, \Delta s))^2 \mid \mathcal{F}_{\lfloor s/\alpha \rfloor}] \leq C \alpha \Delta s \xrightarrow{\alpha \rightarrow 0} 0.$$

Следовательно, $S_2^{(\alpha)}(s, \Delta s) \rightarrow 0$ по вероятности, равномерно на компактных интервалах.

Предел. Из предыдущих шагов следует, что для любого $0 \leq s < t \leq T$ приращение интерполированного процесса можно представить в виде

$$X^{(\alpha)}(t) - X^{(\alpha)}(s) = \int_s^t F(X^{(\alpha)}(u)) du + R^{(\alpha)}(s, t),$$

где остаточный член $R^{(\alpha)}(s, t)$ сходится к нулю по вероятности при $\alpha \rightarrow 0$, равномерно по всем $s, t \in [0, T]$.

Кроме того, из построения следует, что семейство функций $\{X^{(\alpha)}\}_{\alpha>0}$ является равномерно ограниченным на $[0, T]$. В самом деле, при конечном времени T число шагов дискретной динамики пропорционально T/α , а каждое приращение имеет порядок α , так что значения $X^{(\alpha)}(s)$ остаются в компактном множестве с вероятностью, стремящейся к единице при $\alpha \rightarrow 0$.

Далее, из представления приращений следует, что семейство $\{X^{(\alpha)}\}$ является равномерно непрерывным по s : для любых $s < t$ имеем оценку

$$|X^{(\alpha)}(t) - X^{(\alpha)}(s)| \leq \int_s^t |F(X^{(\alpha)}(u))| du + |R^{(\alpha)}(s, t)|,$$

где первый член пропорционален $|t - s|$, а второй исчезает при $\alpha \rightarrow 0$.

Следовательно, по теореме Арцела–Асколи существует подпоследовательность $\alpha_k \rightarrow 0$ такая, что $X^{(\alpha_k)}$ сходится равномерно на $[0, T]$ к некоторой непрерывной функции $x(s)$.

Переходя к пределу по этой подпоследовательности в равенстве для приращений, и используя непрерывность функции F , получаем, что для любых $0 \leq s < t \leq T$ выполняется интегральное соотношение

$$x(t) - x(s) = \int_s^t F(x(u)) du.$$

Из этого следует, что функция x абсолютно непрерывна и почти всюду дифференцируема, причём её производная удовлетворяет

$$\frac{dx}{ds} = F(x(s)) \quad \text{для почти всех } s \in [0, T].$$

Непрерывность правой части обеспечивает, что равенство выполняется для всех $s \in [0, T]$.

Наконец, поскольку обыкновенное дифференциальное уравнение

$$\frac{dx}{ds} = F(x)$$

с заданным начальным условием имеет единственное решение, предел $x(s)$ не зависит от выбора подпоследовательности. Следовательно, вся последовательность процессов $X^{(\alpha)}(s)$ сходится по вероятности, равномерно по $s \in [0, T]$, к функции $x(s)$. $\square$

Замечание 3. Полученная непрерывная динамика описывает усреднённое поведение разности Q-значений на конечных временных интервалах. Флуктуации, связанные со случайным членом, исчезают в этом пределе, однако они становятся существенными при анализе поведения системы на более тонких временных масштабах.

5.4 Флуктуации порядка $\sqrt{\alpha}$

В предыдущем подразделе было доказано, что при $\alpha \rightarrow 0$ интерполированный процесс

$$X^{(\alpha)}(s) := X_{[s/\alpha]}$$

является равномерно ограниченным и равностепенно непрерывным на любом конечном интервале $[0, T]$ и, следовательно, по теореме Арцела–Асколи имеет подпоследовательность, сходящуюся равномерно к предельной функции $x(s)$. Было также показано, что любая такая предельная функция удовлетворяет интегральному уравнению

$$x(t) - x(s) = \int_s^t F(x(u)) du,$$

и потому является решением обыкновенного дифференциального уравнения

$$\frac{dx}{ds} = F(x), \quad x(0) = \lim_{\alpha \rightarrow 0} X^{(\alpha)}(0).$$

Для изучения случайных отклонений от детерминированной траектории $x(s)$ введём центрированный и масштабированный процесс

$$Y^{(\alpha)}(s) := \frac{X^{(\alpha)}(s) - x(s)}{\sqrt{\alpha}}. \quad (9)$$

Выбор масштаба $\sqrt{\alpha}$ является естественным, поскольку за время порядка $1/\alpha$ в динамике накапливается сумма порядка $1/\alpha$ шумовых приращений, каждое из которых имеет порядок α , а их суммарная дисперсия имеет порядок единицы.

5.5 Диффузионное приближение

Теорема 3 (Диффузионный предел для флуктуаций). *Пусть выполняются следующие условия:*

- функция F непрерывна и локально липшицева;
- последовательность случайных величин $\eta(m)$ удовлетворяет

$$\mathbb{E}[\eta(m) \mid \mathcal{F}_m] = 0;$$

- условная дисперсия при фиксированном значении $\Delta Q(m) = x$ имеет вид

$$\mathbb{E}[\eta(m)^2 \mid \Delta Q(m) = x] = \Sigma^2(x),$$

где функция $\Sigma(x)$ непрерывна;

- начальные условия удовлетворяют

$$Y^{(\alpha)}(0) := \frac{X^{(\alpha)}(0) - x(0)}{\sqrt{\alpha}} \xrightarrow{\mathbb{P}} Y(0).$$

Тогда при $\alpha \rightarrow 0$ процесс флуктуаций $Y^{(\alpha)}$ сходится по распределению в пространстве $C([0, T])$ к процессу Y , удовлетворяющему стохастическому дифференциальному уравнению

$$dY_s = F'(x(s)) Y_s ds + \Sigma(x(s)) dW_s, \quad Y(0) \text{ задано.}$$

Доказательство. Дискретная динамика имеет вид

$$X_{m+1} = X_m + \alpha F(X_m) + \alpha \eta(m).$$

Рассмотрим кусочно-постоянную интерполяцию

$$X^{(\alpha)}(s) = X_{\lfloor s/\alpha \rfloor}.$$

Из дискретного уравнения следует представление

$$X^{(\alpha)}(s) = X^{(\alpha)}(0) + \sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \alpha F(X_k) + \sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \alpha \eta(k). \quad (10)$$

Разность между суммой детерминированных членов и интегралом

$$\int_0^s F(X^{(\alpha)}(u)) du$$

стремится к нулю равномерно по $s \in [0, T]$ при $\alpha \rightarrow 0$, поскольку функция F равномерно непрерывна на компактных множествах, а разбиение интервала имеет шаг α .

Следовательно,

$$X^{(\alpha)}(s) = X^{(\alpha)}(0) + \int_0^s F(X^{(\alpha)}(u)) du + M^{(\alpha)}(s) + o_{\mathbb{P}}(1),$$

где

$$M^{(\alpha)}(s) := \sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \alpha \eta(k).$$

Пусть $x(s)$ — решение детерминированного уравнения

$$x(s) = x(0) + \int_0^s F(x(u)) du.$$

Определим процесс флуктуаций

$$Y^{(\alpha)}(s) := \frac{X^{(\alpha)}(s) - x(s)}{\sqrt{\alpha}}.$$

Тогда

$$Y^{(\alpha)}(s) = Y^{(\alpha)}(0) + \int_0^s \frac{F(X^{(\alpha)}(u)) - F(x(u))}{\sqrt{\alpha}} du + \frac{M^{(\alpha)}(s)}{\sqrt{\alpha}} + o_{\mathbb{P}}(1). \quad (11)$$

Рассмотрим асимптотику первого интегрального члена в правой части (11). Напомним, что функция дрейфа F получена как условное математическое ожидание полного приращения и, вообще говоря, может зависеть от состояния всей системы. В дальнейшем под $F(x)$ мы понимаем зависимость от первой переменной, вычисленную вдоль предельной детерминированной траектории $x(\cdot)$.

Предположим, что функция F принадлежит классу C_{loc}^1 по первой переменной. Так как $X^{(\alpha)} \rightarrow x$ по вероятности равномерно на $[0, T]$, существует компактное множество $K \subset \mathbb{R}$ такое, что

$$\mathbb{P}(X^{(\alpha)}(u) \in K, x(u) \in K \text{ для всех } u \in [0, T]) \xrightarrow{\alpha \rightarrow 0} 1.$$

На этом компакте производная F' ограничена и равномерно непрерывна.

Для любых $x, y \in K$ по формуле Ньютона–Лейбница имеем тождество

$$F(y) - F(x) = \int_0^1 F'(x + \theta(y - x)) (y - x) d\theta.$$

Добавляя и вычитая $F'(x)(y - x)$, получаем точное разложение

$$F(y) - F(x) = F'(x)(y - x) + (y - x) \int_0^1 [F'(x + \theta(y - x)) - F'(x)] d\theta.$$

Применяя это тождество к $y = X^{(\alpha)}(u)$ и $x = x(u)$, для каждого $u \in [0, T]$ получаем

$$F(X^{(\alpha)}(u)) - F(x(u)) = F'(x(u)) (X^{(\alpha)}(u) - x(u)) + R^{(\alpha)}(u),$$

где остаточный член имеет вид

$$R^{(\alpha)}(u) = (X^{(\alpha)}(u) - x(u)) \int_0^1 [F'(x(u) + \theta(X^{(\alpha)}(u) - x(u))) - F'(x(u))] d\theta.$$

Так как

$$X^{(\alpha)}(u) - x(u) = \sqrt{\alpha} Y^{(\alpha)}(u),$$

то

$$\frac{R^{(\alpha)}(u)}{\sqrt{\alpha}} = Y^{(\alpha)}(u) \int_0^1 [F'(x(u) + \theta\sqrt{\alpha}Y^{(\alpha)}(u)) - F'(x(u))] d\theta.$$

Из ограниченности по вероятности семейства $Y^{(\alpha)}$ в пространстве $C([0, T])$ следует, что для любого $\varepsilon > 0$ существует $M > 0$ такое, что

$$\mathbb{P}\left(\sup_{u \in [0, T]} |Y^{(\alpha)}(u)| \leq M\right) \geq 1 - \varepsilon.$$

На этом событии аргумент функции F' отличается от $x(u)$ не более чем на $\sqrt{\alpha}M$. Поскольку F' равномерно непрерывна на компакте K , получаем

$$\sup_{u \in [0, T]} \left| \frac{R^{(\alpha)}(u)}{\sqrt{\alpha}} \right| \xrightarrow{\mathbb{P}} 0.$$

Следовательно,

$$\int_0^s \frac{F(X^{(\alpha)}(u)) - F(x(u))}{\sqrt{\alpha}} du = \int_0^s F'(x(u)) Y^{(\alpha)}(u) du + o_{\mathbb{P}}(1).$$

Рассмотрим теперь шумовой член

$$\frac{M^{(\alpha)}(s)}{\sqrt{\alpha}} = \sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \sqrt{\alpha} \eta(k).$$

По предположению о дисперсии при условии $\Delta Q(k) = x$ имеем

$$\mathbb{E}[\eta(k)^2 \mid \Delta Q(k) = x] = \Sigma^2(x).$$

Так как $\Delta Q(k) = X^{(\alpha)}(k\alpha)$, из равномерной сходимости $X^{(\alpha)} \rightarrow x$ и непрерывности функции Σ^2 следует

$$\mathbb{E}[\eta(k)^2] = \Sigma^2(x(k\alpha)) + o(1), \quad \text{равномерно по } k.$$

Рассмотрим равномерное разбиение отрезка $[0, s]$ с шагом α :

$$t_k = k\alpha, \quad k = 0, 1, \dots, \lfloor s/\alpha \rfloor.$$

Тогда

$$\sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \alpha \Sigma^2(x(k\alpha)) = \sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \Sigma^2(x(t_k)) (t_{k+1} - t_k),$$

что является суммой Римана для функции $u \mapsto \Sigma^2(x(u))$. Поскольку эта функция непрерывна на $[0, s]$, получаем

$$\sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \alpha \Sigma^2(x(k\alpha)) \xrightarrow{\alpha \rightarrow 0} \int_0^s \Sigma^2(x(u)) du.$$

Рассмотрим фиксированное $s \in [0, T]$. Случайная величина

$$\frac{M^{(\alpha)}(s)}{\sqrt{\alpha}} = \sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \sqrt{\alpha} \eta(k)$$

является суммой большого числа центрированных слагаемых с суммарной дисперсией

$$\sum_{k=0}^{\lfloor s/\alpha \rfloor - 1} \alpha \mathbb{E}[\eta(k)^2] \rightarrow \int_0^s \Sigma^2(x(u)) du.$$

Следовательно, по центральной предельной теореме

$$\frac{M^{(\alpha)}(s)}{\sqrt{\alpha}} \Rightarrow \mathcal{N}\left(0, \int_0^s \Sigma^2(x(u)) du\right).$$

Аналогично, для любых $0 \leq s_1 < s_2 \leq T$ приращение

$$\frac{M^{(\alpha)}(s_2) - M^{(\alpha)}(s_1)}{\sqrt{\alpha}}$$

асимптотически не коррелировано с $\frac{M^{(\alpha)}(s_1)}{\sqrt{\alpha}}$, что в пределе приводит к независимости приращений.

Таким образом, конечномерные распределения процесса $\frac{M^{(\alpha)}}{\sqrt{\alpha}}$ сходятся к гауссовским распределениям с ковариационной функцией

$$\mathbb{E}[Z(s)Z(t)] = \int_0^{\min(s,t)} \Sigma^2(x(u)) du.$$

Поэтому предельный процесс может быть представлен в виде стохастического интеграла

$$Z(s) = \int_0^s \Sigma(x(u)) dW_u,$$

где W — стандартный винеровский процесс.

Переходя к пределу в (11), получаем, что любой предельный процесс Y удовлетворяет интегральному уравнению

$$Y(s) = Y(0) + \int_0^s F'(x(u)) Y(u) du + \int_0^s \Sigma(x(u)) dW_u.$$

Линейность этого уравнения обеспечивает единственность решения, что завершает доказательство. □

5.6 Локальная линейная аппроксимация вблизи дефектного равновесия

Дальнейший анализ посвящён поведению процесса флуктуаций в окрестности дефектного равновесия x^* , определённого как устойчивое равновесие детерминированной предельной динамики, то есть

$$F(x^*) = 0, \quad F'(x^*) < 0.$$

Напомним, что процесс флуктуаций Y удовлетворяет стохастическому дифференциальному уравнению

$$dY_s = F'(x(s)) Y_s ds + \Sigma(x(s)) dW_s,$$

где $x(s)$ — решение детерминированного уравнения

$$\dot{x} = F(x), \quad x(0) \text{ задано.}$$

Теорема 4 (Локальная линейная аппроксимация). *Существует $\delta > 0$ такое, что если $|x(0) - x^*| < \delta$, то на временных интервалах, пока $x(s)$ остаётся в δ -окрестности точки x^* , процесс флуктуаций Y аппроксимируется решением линейного стохастического уравнения*

$$dZ_s = -\kappa Z_s ds + \Sigma(x^*) dW_s, \quad \kappa := -F'(x^*) > 0,$$

то есть процессом Орнштейна–Уленбека.

Доказательство. Поскольку $F \in C_{\text{loc}}^1$ по первой переменной, из условий $F(x^*) = 0$ и $F'(x^*) < 0$ следует, что в окрестности x^* справедливо разложение

$$F'(x) = F'(x^*) + o(1) \quad \text{при } x \rightarrow x^*.$$

Если начальное условие $x(0)$ достаточно близко к x^* , то устойчивость равновесия гарантирует, что $x(s)$ остаётся в малой окрестности x^* на рассматриваемом временном интервале. Следовательно,

$$F'(x(s)) = -\kappa + o(1), \quad \Sigma(x(s)) = \Sigma(x^*) + o(1),$$

где остаточные члены стремятся к нулю равномерно по s на каждом фиксированном конечном интервале времени.

Отбрасывая высшие порядки малости, получаем линейное стохастическое уравнение с постоянными коэффициентами, которое и совпадает с уравнением Орнштейна–Уленбека. $\square$

Замечание 4. Полученная линейная аппроксимация описывает типичное поведение флуктуаций вблизи устойчивого дефектного равновесия. Именно эта аппроксимация будет использована в следующем разделе для анализа времени выхода процесса из малой окрестности точки x^* .

6 Ловушка дефекции и время выхода

В данном разделе мы формализуем понятие ловушки дефекции и выводим асимптотическую формулу для среднего времени выхода из неё в пределе малого шага обучения $\alpha \rightarrow 0$.

6.1 Определение ловушки дефекции

Определение 3 (Дефектная ловушка). Для фиксированного $\varepsilon \in (0, 1)$ дефектная ловушка определяется как множество

$$\mathcal{T}_\varepsilon = \{x \in \mathbb{R} : \sigma(\beta x) \leq \varepsilon\}.$$

Граница ловушки имеет координату

$$x_{\text{bd}} = \frac{1}{\beta} \log \frac{\varepsilon}{1 - \varepsilon}.$$

Расстояние от дефектного равновесия x^* до границы ловушки равно

$$\Delta := x_{\text{bd}} - x^* > 0.$$

Замечание 5. Множество $\mathcal{T}_\varepsilon$ соответствует области состояний, в которых вероятность кооперации экспоненциально мала.

6.2 Формулировка задачи о времени выхода

Вблизи дефектного равновесия x^* динамика исходного процесса обучения может быть аппроксимирована одномерным стохастическим процессом с малым шумом. В рамках локальной линейной аппроксимации (см. Теорему 4) мы рассматриваем процесс X_s , удовлетворяющий стохастическому уравнению

$$dX_s = -\kappa(X_s - x^*) ds + \sqrt{\alpha} \Sigma(x^*) dW_s,$$

где $\kappa > 0$, а параметр α характеризует величину шума.

Определение 4 (Время выхода). Временем выхода из дефектной ловушки называется случайная величина

$$\tau_{\text{exit}} = \inf\{s \geq 0 : X_s \notin \mathcal{T}_\varepsilon\}.$$

Наша цель состоит в исследовании асимптотики математического ожидания $\mathbb{E}[\tau_{\text{exit}}]$ при $\alpha \rightarrow 0$.

6.3 Квазипотенциал и энергетический барьер

Рассмотрим стохастический процесс

$$dX_s = -\kappa(X_s - x^*) ds + \sqrt{\alpha} \Sigma(x^*) dW_s,$$

который используется в качестве локальной модели динамики исходного процесса обучения вблизи дефектного равновесия x^* .

Детерминированная часть этого уравнения имеет вид

$$-\kappa(x - x^*) = -\frac{d}{dx} V(x),$$

где функция

$$V(x) = \frac{\kappa}{2} (x - x^*)^2$$

играет роль потенциальной энергии. В этом смысле процесс X_s является одномерной градиентной диффузией с малым шумом.

В теории больших уклонений для стохастических дифференциальных уравнений с малым шумом ключевую роль играет *квазипотенциал*, который описывает асимптотику вероятностей редких переходов между состояниями. В случае одномерной градиентной диффузии квазипотенциал между точками совпадает с разностью значений функции V .

Лемма 7 (Высота потенциального барьера). *Разность квазипотенциала между устойчивым равновесием x^* и границей дефектной ловушки x_{bd} равна*

$$\Delta V = V(x_{\text{bd}}) - V(x^*) = \frac{\kappa}{2} (x_{\text{bd}} - x^*)^2 = \frac{\kappa \Delta^2}{2}.$$

Доказательство. По определению функции V имеем $V(x^*) = 0$. Подставляя $x = x_{\text{bd}}$ и используя обозначение $\Delta = x_{\text{bd}} - x^*$, получаем

$$\Delta V = \frac{\kappa}{2} \Delta^2,$$

что и требовалось доказать. □

Замечание 6. Величина ΔV характеризует энергетический барьер, который процесс должен преодолеть для выхода из дефектной ловушки. В следующем разделе будет показано, что именно эта величина определяет экспоненциальный масштаб среднего времени выхода при $\alpha \rightarrow 0$.

6.4 Теорема о времени выхода

Теорема 5 (Экспоненциальная асимптотика времени выхода). *Рассмотрим процесс X_s , удовлетворяющий стохастическому уравнению*

$$dX_s = -\kappa(X_s - x^*) ds + \sqrt{\alpha} \Sigma(x^*) dW_s,$$

и пусть начальное условие X_0 принадлежит фиксированной окрестности точки x^ , не зависящей от α . Тогда при $\alpha \rightarrow 0$ математическое ожидание времени выхода τ_{exit} из дефектной ловушки $\mathcal{T}_\varepsilon$ обладает логарифмической асимптотикой*

$$\lim_{\alpha \rightarrow 0} \alpha \log \mathbb{E}[\tau_{\text{exit}}] = \frac{\kappa \Delta^2}{\Sigma^2(x^*)}.$$

В частности,

$$\mathbb{E}[\tau_{\text{exit}}] = \exp\left(\frac{\kappa \Delta^2}{\alpha \Sigma^2(x^*)}\right) \cdot (1 + o(1)).$$

Доказательство. Рассматриваемый процесс является одномерной диффузией с малым шумом порядка $\sqrt{\alpha}$ и единственным устойчивым равновесием x^* внутри области $\mathcal{T}_\varepsilon$. Для таких процессов теория больших уклонений для стохастических дифференциальных уравнений с малым шумом (см. теорию Фрейдлина–Вентцеля) утверждает, что логарифмическая асимптотика среднего времени выхода из области притяжения устойчивого равновесия определяется высотой квазипотенциального барьера:

$$\lim_{\alpha \rightarrow 0} \alpha \log \mathbb{E}[\tau_{\text{exit}}] = \frac{2\Delta V}{\Sigma^2(x^*)}.$$

В рассматриваемом случае, согласно Лемме 7, разность квазипотенциала равна

$$\Delta V = \frac{\kappa \Delta^2}{2}.$$

Подстановка этого выражения даёт

$$\lim_{\alpha \rightarrow 0} \alpha \log \mathbb{E}[\tau_{\text{exit}}] = \frac{\kappa \Delta^2}{\Sigma^2(x^*)}.$$

Утверждение теоремы о форме экспоненциальной асимптотики следует из данного равенства. Предэкспоненциальный множитель зависит от локальной геометрии коэффициентов и в данной работе не анализируется, поскольку он не влияет на главный экспоненциальный порядок. $\square$

6.5 Интерпретация результата

Замечание 7. Экспоненциальный характер времени выхода обусловлен совместным действием следующих факторов:

- малой интенсивности стохастических флуктуаций, пропорциональной $\sqrt{\alpha}$;
- линейной силы возврата к дефектному равновесию, характеризуемой коэффициентом κ ;
- конечного расстояния Δ между дефектным равновесием и границей ловушки.

В результате даже умеренное уменьшение шага обучения α приводит к резкому увеличению типичного времени пребывания системы в дефектной области.

Замечание 8. Полученная асимптотика даёт теоретическое объяснение наблюдаемому в численных экспериментах эффекту длительного удержания системы в режиме дефекции при малых шагах обучения. В рамках построенной модели такое поведение является следствием редкости флуктуаций, достаточных для выхода из дефектной ловушки, а не наличия дополнительных поглощающих состояний.

7 Заключение

В работе построена строгая асимптотическая теория дефектных ловушек в многоагентном Q-обучении в пределе малого шага обучения. Исходная дискретная динамика обучения была сведена к одномерному стохастическому процессу, для которого последовательно получены детерминированный предел, диффузионное приближение и локальная линейная аппроксимация вблизи дефектного равновесия.

Показано, что в режиме малого шума выход из дефектной области является редким событием, а среднее время выхода обладает экспоненциальной асимптотикой по параметру α^{-1} . Главный экспоненциальный порядок определяется высотой квазипотенциального барьера и не зависит от деталей предэкспоненциального множителя.

Полученные результаты объясняют устойчивость дефектного поведения, наблюдаемую в численных экспериментах по многоагентному обучению с подкреплением, и демонстрируют, что она может возникать как следствие динамики обучения, даже при отсутствии явно поглощающих состояний.